EIZ / PRIRUČNIK ZA SAMOSTALNO ČITANJE

istraživanje uz umjetnu inteligenciju

Prošireni tekst obaju dana radionice

Izvorni materijal / Luka Šikić, UNICATH

Revidirano izdanje / 27. listopada 2026.



OSAM POGLAVLJA / IZVORI · ANALIZA · PISANJE

Materijali za radionicu i samostalno čitanje.

Sadržaj

Kako čitati ovaj priručnik 3

Prvi dan / od pitanja do provjerenih izvora 4

1.1 Postavite istraživačko pitanje 4

1.2 Pronađite i provjerite izvore 6

1.3 Provjerite i uredite sažetak 8

1.4 Pripremite plan analize 10

Drugi dan / od podataka do zaključka 12

2.1 Upoznajte i provjerite podatke 12

2.2 Izradite i objasnite prikaze 14

2.3 Ponovite analizu od početka 16

2.4 Napišite i uredite zaključak 18

Poveznice u sadržaju i bočne oznake PDF-a vode na poglavlja. Podcrtane poveznice uz tvrdnje vode na izvorne dokumente. Tekst možete pretraživati i označavati.

Kako čitati ovaj priručnik

U ovom priručniku prolazimo kroz malo istraživanje, od prvog pitanja do objašnjenja rezultata. Poglavlja prate dva dana radionice, ali možete ih čitati i zasebno. Cijelo vrijeme radimo s istim podacima: 120 mjesečnih opažanja za Hrvatsku od siječnja 2015. do prosinca 2024. Uspoređujemo godišnju stopu HICP-a i saldo očekivanih promjena cijena. Podaci su preuzeti 26. listopada 2026. i spremljeni uz materijale.

Trebat će vam AI alat koji može učitati CSV i provesti izračune. Datoteku dodajte na početku razgovora, a zatim običnim jezikom zadajte što želite saznati. Upite iz priručnika možete preuzeti i prilagoditi svojem pitanju. Programsko predznanje nije potrebno.

Na početku svakog poglavlja nalaze se pitanje za razgovor, primjer i zadatak koji možete sami isprobati. U nastavku objašnjavamo zašto biramo određeni postupak i što iz njegova rezultata možemo saznati. Voditelj može pokazati primjer, a sudionici predložiti drukčiji prikaz ili tumačenje. Ako alat nije dostupan ili izračun ne uspije, razgovor možete nastaviti uz pripremljene grafove i brojke.

Prvi dan biramo pitanje, tražimo i čitamo izvore te pripremamo plan. Drugi dan upoznajemo podatke, izrađujemo prikaze, uspoređujemo razdoblja i pišemo zaključak. Brojevi poglavlja odgovaraju temama na stranicama radionice. Na kraju ćete imati odabrani graf i kratak odgovor na svoje pitanje, spreman za razgovor s kolegom.

Na nekoliko mjesta oslanjamo se na rasprave Paula Goldsmith-Pinkhama o AI-ju u istraživanju. Zanima nas što se mijenja kada je lakše provesti ideju, kako procijeniti dobiveni rezultat i zašto nam pisanje pomaže razmišljati. Njegove tekstove i demonstracije koristimo kao povod za raspravu. Njihove pouke treba procijeniti na vlastitom zadatku. Odabrani tekstovi nalaze se na kratkom popisu za čitanje.

Autor izvornih materijala je Luka Šikić, UNICATH. Izdanje je revidirano 27. listopada 2026. Podrijetlo podataka i referentni rezultati opisani su u priloženim materijalima radionice.

Prvi dan / od pitanja do provjerenih izvora

1.1 Postavite istraživačko pitanje

Dan 1, tema 1.1 · Vježba 1.1

Primjer iz radionice

Razgovor. Koje pitanje možemo istražiti s dvije mjesečne serije za Hrvatsku?

Primjer. Od teme „inflacija i očekivanja" dolazimo do pitanja o kretanju dviju mjera od 2015. do 2024. i njihovoj povezanosti u različitim razdobljima.

Isprobajte. Odaberite razdoblje ili obrazac koji vas zanima. Zatražite prijedlog pitanja i objasnite kakav bi vam prikaz pomogao odgovoriti na njega.

Što se mijenja kada je lakše provesti ideju

Prije prvog grafa treba pronaći podatke, razumjeti njihove oznake i odlučiti što usporediti. Već tu dobra ideja može zapeti. AI može olakšati taj posao: objasniti nepoznat pojam, predložiti prikaz ili pomoći da isprobamo drukčije objašnjenje. Tako možemo provjeriti vrijedi li razvijati i ideju koju bismo prije odgodili zbog opsežne početne obrade.

Paul Goldsmith-Pinkham u tekstu Research in the Time of AI opisuje kako jeftinija izvedba mijenja istraživački rad. Kada je lakše pripremiti podatke i dobiti rezultate, više pažnje možemo posvetiti izboru pitanja i smislu odgovora. To traži poznavanje teme i dobru prosudbu. Na radionici ćemo zato uz svaki rezultat razgovarati o tome što smo htjeli saznati i što bismo napravili sljedeće.

S našim podacima možemo usporediti ranije i kasnije godine, pogledati razdoblje ubrzanja cijena ili istražiti kreću li se dvije mjere zajedno. Ako želimo objasniti što je uzrokovalo promjenu, morat ćemo osmisliti istraživanje koje može razlikovati moguća objašnjenja.

Što poznavanje teme donosi pitanju

Luka Šikić u pregledu How Economics Absorbed AI ističe vrijednost poznavanja određenog područja, jezika i izvora podataka. To može biti polazište i za vaš izbor teme. U hrvatskom primjeru poznavanje lokalnih rasprava o cijenama može vas navesti na pitanje koje općeniti upit o inflaciji ne bi otvorio.

Recite koju biste okolnost izdvojili nekome tko slabo poznaje Hrvatsku. Što biste zbog nje željeli istražiti? Potom razjasnite imamo li u tablici mjeru koja bi pomogla odgovoriti. Poznavanje konteksta pomaže osmisliti pitanje, a podaci određuju koliko mu se možemo približiti.

Od teme do pitanja na koje možemo odgovoriti

Tema „inflacija u Hrvatskoj” obuhvaća mnogo različitih istraživanja. Pitanje „Kako su se godišnja stopa HICP-a i saldo očekivanih promjena cijena kretali od 2015. do 2024.?” već određuje zemlju, vrijeme i dvije mjere. Iz njega možemo zamisliti prikaz i objasniti što će čitatelj saznati.

> U učitanom skupu imamo 120 mjeseci za Hrvatsku, godišnju stopu HICP-a i saldo očekivanih promjena cijena. Predloži tri opisna pitanja koja možemo istražiti tim podacima. Za svako objasni što bismo saznali i koji bi prikaz pomogao odgovoriti. Zatim mi postavi jedno pitanje koje će mi pomoći odabrati temu.

Odaberite prijedlog koji vas zanima. Pitanje o 2022. usmjerava pogled na naglu promjenu cijena, dok usporedba dvaju petogodišnjih razdoblja ispituje koliko je odnos stabilan. Objasnite što biste odgovorom na svoje pitanje dodali početnom opisu. Ako vam to još nije jasno, razradite pitanje prije nego što zatražite nove rezultate.

Prvi graf može vas navesti na novo pitanje. Recite što vas je na njemu iznenadilo i kako je to promijenilo početnu zamisao. Pitanje koje ste postavili nakon gledanja podataka treba razlikovati od hipoteze koju ste namjeravali ispitati prije analize.

Kako razgovaramo s modelom

Jezični model oblikuje odgovor koristeći naučene obrasce i sadržaj koji mu je dostupan u razgovoru. Tekst obrađuje u manjim jedinicama, tokenima, i postupno sastavlja nastavak. Aplikacija mu može omogućiti i korištenje alata, primjerice pretraživanje, čitanje dokumenta ili izvođenje izračuna. Zbog toga je korisno jasno reći kada tražite ideju, kada objašnjenje pročitanog izvora, a kada račun iz učitane tablice.

Kontekst je sadržaj koji je modelu trenutačno dostupan. U dugom razgovoru raniji dijelovi mogu biti sažeti ili izostavljeni. Prije novog zadatka kratko ponovite pitanje i važnu odluku. Primjerice, podsjetite ga da analizirate cijelo desetljeće i da je saldo izražen u bodovima. Tako smanjujete mogućnost da se nastavak osloni na pogrešnu pretpostavku.

Odaberite dostupan alat koji može čitati datoteke i provoditi izračune. Isprobajte ga na svojem pitanju i pogledajte pomaže li vam razumjeti rezultat. O tome je li pitanje zanimljivo ili koje ste objašnjenje previdjeli razgovarajte i s kolegama.

Brzina i razumijevanje

AI može proizvesti nove rezultate brže nego što ih stignemo razumjeti. Goldsmith-Pinkham taj zaostatak naziva dugom provjere. Na radionici ga možemo prepoznati kada već imamo nekoliko tablica, a još ne znamo objasniti što sažima prva. Tada je korisnije zadržati se na jednom nalazu i razjasniti njegov smisao.

Kad dobijete prvi graf, pokušajte o njemu napisati jednu jasnu rečenicu. Ako to ide sporije od izrade grafa, zastanite i razjasnite što vam je nejasno. Možda je problem u značenju mjere, a možda još ne znate koji je obrazac važan za vaše pitanje.

1.2 Pronađite i provjerite izvore

Dan 1, tema 1.2 · Vježba 1.2

Primjer iz radionice

Razgovor. Kako definicija mjere utječe na usporedbu inflacije i očekivanja?

Primjer. U Eurostatovu opisu HICP-a pronađemo značenje godišnje stope. Vrijednost za ožujak 2022. uspoređuje cijene s ožujkom 2021., iako naša tablica ima zaseban redak za svaki mjesec.

Isprobajte. U metodologiji Europske komisije pronađite pitanje CONS_006 i objašnjenje salda. Objasnite što odgovori govore o budućem kretanju cijena i predložite naziv okomite osi grafa.

Pretraživanje koje prati pitanje

Pretraga o inflaciji vratit će vijesti, službene podatke i istraživačke radove. Vijest može upozoriti na zanimljivu promjenu, metodologija objasniti mjeru, a istraživački rad ponuditi i ispitati neko objašnjenje. Prije pretrage odredite što vam od toga nedostaje.

AI pretraživanje može predložiti pojmove i sažeti pronađene izvore. Perplexity i slični alati mogu poslužiti za prvi pregled teme. Zatražite poveznice kako biste mogli otvoriti rad koji vas zanima. Ako je alatu dostupan samo sažetak, ne može iz njega pouzdano opisati sve pojedinosti provedenog istraživanja.

Početni upit može biti vrlo kratak.

> Inflacija Hrvatska.

Takav zahtjev ne razlikuje aktualnu stopu od objašnjenja inflacije ili istraživanja očekivanja. Precizniji upit određuje odnos koji vas zanima.

> Pronađi istraživanja o tome kako kućanstva oblikuju očekivanja o budućim promjenama cijena. Usmjeri se na europske zemlje. Za svaki odabrani rad ukratko objasni pitanje, podatke i glavni doprinos temi te navedi poveznicu na izvor. Naznači čitaš li puni tekst ili sažetak.

U međunarodnoj literaturi tražite izraz inflation expectations, a hrvatskim pojmovima dopunite pretragu lokalnih izvora. Zatim je suzite na ono što bi moglo oblikovati očekivanja: iskustvo kupnje, informacije iz medija ili povjerenje u institucije. Pronađeni radovi tada će biti bliži pitanju koje pokušavate postaviti.

Što pretraga nije mogla pročitati

U dodatku What can be read Šikić razlikuje zapis o radu od dostupnosti njegova punog teksta. Njegova je zbirka odabrani pregled, ali otvara važno pitanje za svaku pretragu: utječe li dostupnost na sliku literature koju dobivamo? Lako dostupan vodič može zauzeti više mjesta u AI sažetku od rada kojemu alat vidi samo naslov.

Odaberite jedan važan rad i potražite autorsku verziju ili pristup preko knjižnice. Zatim usporedite što ste o njemu znali prije i nakon čitanja. Ako neki izvor nedostaje iz odgovora, to još ne znači da o toj temi nema istraživanja.

Što zapravo pitamo potrošače

Za naš je primjer važno razlikovati percepciju prošlih promjena cijena od očekivanja budućih promjena. Anketno pitanje CONS_006 traži procjenu kretanja cijena u sljedećih dvanaest mjeseci u usporedbi s proteklih dvanaest mjeseci. Ponuđene su kategorije odgovora, iz kojih se računa saldo. Njegova vrijednost govori o raspodjeli odgovora prema pravilima ankete. Iz vrijednosti 40 bodova ne možemo zaključiti da ispitanici očekuju stopu inflacije od 40 posto.

Otvorite metodologiju Europske komisije i pročitajte pitanje uz ponuđene odgovore. U Eurostatovu opisu HICP-a pogledajte kako se određuje godišnja promjena. Naša usporedba povezuje mjeru ostvarenog kretanja cijena s kvalitativnom mjerom očekivanja. Različite jedinice kasnije će odrediti kako oblikujemo grafove.

> Objasni razliku između godišnje stope HICP-a i salda iz pitanja CONS_006. Osloni se na ova dva službena opisa. Za svaku mjeru predloži jasnu oznaku osi i jednu rečenicu kojom bih je predstavio osobi koja prvi put vidi graf.

Što bi značio rast salda u našoj tablici? Odgovorite uz formulaciju anketnog pitanja. Govori li o promjeni raspodjele odgovora, o većem očekivanom ubrzanju cijena ili o točno određenoj budućoj stopi? Ako se tumačenja razlikuju, ponovno pročitajte ponuđene kategorije odgovora.

Zašto nam treba baš taj izvor

Članak Meylera i Reiche u ECB Economic Bulletinu pomaže razumjeti kvalitativne i kvantitativne mjere percepcija i očekivanja. Koristimo ga da objasnimo što mjerimo. Korelaciju za hrvatski primjer računamo iz svoje tablice. Kad navodite izvor, recite čemu vam služi: objašnjava li pojam, predlaže mogući uzrok ili donosi nalaz koji uspoređujete sa svojim?

Ako dvije studije dolaze do različitih zaključaka, usporedite njihova pitanja i okolnosti. Jedna može ispitivati kratku informacijsku intervenciju, a druga dugoročna kretanja u anketi. Ta razlika može objasniti neslaganje bolje od pokušaja da njihove nalaze spojite u jednu opću tvrdnju.

Odaberite jedan rad zbog kojeg ste promijenili početno mišljenje o temi. Objasnite što biste bez njega pogrešno pretpostavili i što vam nakon čitanja još nedostaje. To će vam pomoći odlučiti što tražiti sljedeće.

1.3 Provjerite i uredite sažetak

Dan 1, tema 1.3 · Vježba 1.3

Primjer iz radionice

Razgovor. Kako sažimanjem možemo promijeniti značenje nalaza?

Primjer. Usporedimo rečenicu o pozitivnoj korelaciji s tvrdnjom da očekivanja uzrokuju inflaciju. Razgovaramo o tome što je u drugoj rečenici dodano izvan samog rezultata.

Isprobajte. Preradite ovaj namjerno pogrešan odlomak. Objasnite komu ili čemu opažanja pripadaju, kako su izražene mjere i na koje se razdoblje zaključak odnosi.

> U uzorku od 120 hrvatskih kućanstava očekivana inflacija 2022. iznosila je prosječno 46,62 %. Korelacija s ostvarenom inflacijom od približno 0,70 pokazuje da su potrošači uspješno predvidjeli buduće cijene. Isti zaključak vrijedi za svako razdoblje od 2015. do 2024.

Što dobar sažetak čuva

Dobar sažetak omogućuje čitatelju da razumije što je istraživanje pitalo, kako je provedeno i što je ustanovilo. Ne mora ponoviti sve pojedinosti. Mora zadržati one bez kojih bi nalaz dobio drukčije značenje, primjerice na koga se odnosi ili što ostaje neobjašnjeno.

Primjerice, „dvije mjere u istom mjesecu pozitivno su povezane” i „potrošači su uspješno predvidjeli inflaciju” govore o različitim odnosima. Druga tvrdnja zahtijeva povezivanje ranijih očekivanja s odgovarajućim kasnijim ishodom. Ako taj korak izostavimo iz sažetka, čitatelj može steći dojam da je provedena analiza koju zapravo nemamo.

Goldsmith-Pinkham u prijedlogu LLM-Friendly Academic Papers zagovara istraživačke materijale iz kojih modeli mogu lakše prenijeti nalaze i njihova ograničenja. To možemo primijeniti i na svoj odlomak. Uz glavni nalaz napišite što iz njega još ne znamo. Čitatelj tako dobiva oba dijela objašnjenja na istome mjestu.

> Sažmi ovaj odlomak za sudionika radionice. Zadrži pitanje, uzorak, značenje mjera i glavni nalaz. Objasni što iz tog nalaza još ne možemo zaključiti. Zatim navedi jednu važnu pojedinost koju si izostavio zbog kratkoće i zašto.

Usporedite izvorni odlomak sa sažetkom. Je li kraća verzija jasnija? Je li izostavljena pojedinost koja mijenja smisao? Zadržite ono što vašoj publici treba da bi razumjela nalaz, čak i ako sažetak zbog toga bude nešto dulji.

Kad sažetak govori o budućnosti

Šikićev pregled predviđanja uz očekivani događaj navodi rok, procjenu vjerojatnosti i uvjete po kojima će se kasnije ocijeniti. Takav zapis pomaže sačuvati razliku između onoga što se dogodilo i onoga što autor očekuje. Navedena vjerojatnost izražava procjenu autora, a nije izmjeren udio događaja.

Uzmite tvrdnju „AI će promijeniti istraživački rad” i pokušajte reći koju biste promjenu mogli opažati, kod koga i do kada. Koji bi nalaz govorio protiv vašeg očekivanja? U sažetku tu rečenicu predstavite kao predviđanje. Jednako tako, rast salda očekivanja u našoj tablici još nije nalaz o tome što se poslije dogodilo s cijenama.

Kako povezati više pročitanih radova

U pregledu literature treba povezati pročitane radove. Gdje se njihova objašnjenja slažu, a gdje razilaze? Zašto je to važno za naše pitanje? Kod inflacijskih očekivanja radove možemo usporediti prema tome kako mjere očekivanja, koje informacije proučavaju i kakav odnos pokušavaju ustanoviti.

Istraživački načini rada, poput Deep Researcha, mogu pomoći u organiziranju opsežnije pretrage. Prije prikupljanja materijala razgovarajte s alatom o svrsi pregleda. Ako vas zanima medijsko izvještavanje, povijest monetarne politike može biti kratak kontekst, dok više prostora zaslužuju mjerenje medijske pažnje i način na koji studije povezuju informacije s očekivanjima.

> Predloži plan pregleda literature o medijskom izvještavanju i inflacijskim očekivanjima kućanstava. Poveži ga s našim pitanjem o Hrvatskoj. Organiziraj ga oko mjerenja očekivanja, uloge informacija i istraživačkih pristupa. Za svaki dio objasni kako bi pomogao razumjeti temu. Najprije razgovarajmo o planu.

Nakon prvih radova možda ćete promijeniti plan. Ako se dio literature bavi percepcijama, razjasnite razliku između prošlih i budućih promjena cijena. Ako radovi proučavaju druge zemlje, razmislite što bi u Hrvatskoj moglo biti drukčije i zašto bi to utjecalo na zaključak.

Od pregleda literature do vlastite ideje

Neslaganje među radovima može postati početak dobrog pitanja. Primjerice, odnos informacija i očekivanja mogao bi ovisiti o tome je li inflacija dugo niska ili se upravo naglo mijenja. Takva ideja može motivirati opisnu usporedbu razdoblja u našem skupu. Rezultat usporedbe potom pomaže odlučiti kakav bi daljnji projekt bio smislen.

Zatražite nekoliko mogućih objašnjenja istog obrasca. Za jedno od njih pokušajte reći što biste očekivali vidjeti u podacima. Zatim razmotrite bi li isti obrazac mogao nastati i zbog nekog drugog razloga. Takva usporedba pomaže odrediti koje biste podatke trebali prikupiti.

Literatura nam može pomoći osmisliti istraživanje uloge medija. Naša tablica, međutim, sadrži samo inflaciju i anketni saldo. Za odgovor o medijima trebali bismo prikupiti i podatke o izvještavanju.

1.4 Pripremite plan analize

Dan 1, tema 1.4 · Vježba 1.4

Primjer iz radionice

Razgovor. Koji prikaz i usporedba odgovaraju našem pitanju?

Primjer. Predložimo slijed: upoznati podatke, prikazati dvije serije, sažeti ih po godinama, usporediti razdoblja i objasniti nalaz.

Isprobajte. Prilagodite plan svojem pitanju. Objasnite zašto biste zadržali jedan predloženi korak, a drugi promijenili ili izostavili.

Plan kao razgovor o izborima

Planom određujemo kako ćemo odgovoriti na pitanje. Ako nas zanima kada su mjere najviše rasle, trebamo vremenski graf. Ako želimo usporediti njihov odnos u dva razdoblja, trebamo iste sažetke za oba. Prije izračuna trebali bismo moći objasniti čemu svaki korak služi.

AI može predložiti nekoliko postupaka. Zatražite da objasni zašto predlaže baš taj graf ili razdoblje i što bismo saznali dodatnim izračunom. Slična biste pitanja postavili i kolegi. Odaberite plan koji odgovara vašem pitanju i koji možete obrazložiti.

> Želim opisati kako se odnos godišnje stope HICP-a i salda očekivanih promjena cijena razlikuje između 2015.–2019. i 2020.–2024. Predloži kratak plan koristeći učitane podatke. Za svaki korak objasni što ćemo saznati. Ponudi jednu jednostavniju varijantu plana i reci što bismo njome izgubili.

Prođite kroz predložene rezultate. Donosi li svaki graf nešto novo? Ako nekoliko njih pokazuje gotovo isto, odaberite najjasniji. Ostavite dovoljno vremena da protumačite ono što ste dobili.

Dijelovi istraživanja ovise jedni o drugima

Goldsmith-Pinkham u tekstu AI and the Research O-Ring uspoređuje istraživanje s procesom čiji koraci ovise jedni o drugima. Slabost jednog koraka može umanjiti vrijednost cijelog rada. Ta ekonomska analogija dobro opisuje i problem koji se može pojaviti u našem primjeru.

U našem primjeru pogrešno razumijevanje salda utjecalo bi na oznaku osi, usporedbu s HICP-om i tekst zaključka. Račun može biti točan, a tumačenje i dalje pogrešno. Zato planiranje uključuje razgovor o mjerama i pitanju, a kasniji rezultati mogu nas vratiti na te odluke.

Ponekad nas rezultat vrati na početno pitanje. Ako graf pokaže da se odnos mijenja kroz vrijeme, možda će nas više zanimati razlike među razdobljima nego prosjek za cijelo desetljeće. Objasnite što vas je navelo na tu promjenu i prilagodite joj plan.

Zadajte izvediv korak

Za početak zatražite jedan prikaz ili jednu usporedbu. Kad razumijete rezultat, odlučite što dalje. Ako alat predloži novu metodu, pitajte koje pitanje ona rješava i kakve podatke zahtijeva. Njezin naziv sam po sebi nije razlog da je uključite u analizu.

> Za početak prikaži obje mjere kroz svih 120 mjeseci u odvojenim panelima sa zajedničkom vremenskom osi. Objasni što se iz takva prikaza može vidjeti. Zatim predloži jednu usporedbu koja bi pomogla odgovoriti na moje pitanje o razdobljima.

Ako je prijedlog preširok, suzite ga običnim jezikom: „Zadržimo se na usporedbi razdoblja" ili „Objasni najprije kako bi se čitao taj prikaz". Ako odgovor pretpostavlja medijske podatke koje nemamo, razdvojite zadatak koji je sada izvediv od zamisli za novi projekt.

Uputu koja vam se pokazala korisnom možete sačuvati i prilagoditi sljedećem zadatku. Goldsmith-Pinkham o tome piše kroz ponovno upotrebljive upute, odnosno skills. Na radionici to može biti jednostavan upit za izradu prikaza ili komentar na tekst. Pri ponovnoj uporabi provjerite odgovara li uputa novim podacima i pitanju.

Plan koji možete prenijeti u drugi alat

U pregledu How Economics Absorbed AI Šikić predlaže da postupak opišemo odvojeno od proizvoda u kojem ga trenutačno izvodimo. Za našu analizu bitne su odluke o mjerama, razdoblju i usporedbi. Nazivi izbornika pomažu dok koristimo jednu aplikaciju, ali sami ne objašnjavaju analizu.

Pokušajte kolegi prenijeti plan bez spominjanja naziva alata. Može li iz njega razumjeti koje podatke treba, što treba napraviti i kako će izgledati rezultat? Dio koji ostane nejasan dopunite prije rada. Takav plan možete upotrijebiti i nakon promjene aplikacije.

Povežite prvi i drugi dan

Na kraju prvog dana svatko ukratko predstavi pitanje, odabrani prikaz i usporedbu koju želi napraviti. Kolega može pitati zašto je baš ta usporedba korisna ili predložiti jednostavniji put. Taj razgovor često razjasni dio plana koji je u razgovoru s AI-jem ostao neodređen.

Na kraju razgovora zatražite kratak sažetak pitanja i dogovorene usporedbe. Od njega možete krenuti drugi dan. Ako se sesija prekine, ponovno dodajte isti CSV i navedite što želite istražiti. Tako rad možete nastaviti i u drugom alatu.

Drugi dan / od podataka do zaključka

2.1 Upoznajte i provjerite podatke

Dan 2, tema 2.1 · Vježba 2.1

Primjer iz radionice

Razgovor. Što predstavlja jedan redak naše tablice i kako iz njega čitamo dvije mjere?

Primjer. Zatražimo kratak opis učitanog skupa i pogledamo nekoliko mjeseci na početku i kraju razdoblja. Povežemo prikazane vrijednosti sa značenjem HICP-a i anketnog salda.

Isprobajte. Odaberite jedan mjesec i objasnite što njegove vrijednosti govore, na koje se vrijeme odnose i što biste o njima htjeli saznati.

Prvi pogled na tablicu

Nastavite u razgovoru iz prvog dana. Ako počinjete ovdje, preuzmite CSV radionice, dodajte ga u alat koji može izvršavati analizu i navedite pitanje koje ste odabrali. Za prvi pregled dovoljan je kratak zahtjev.

> Upoznaj me s učitanom tablicom. Opiši što predstavlja jedan redak, koliko mjeseci obuhvaća i koje dvije mjere analiziramo. Prikaži nekoliko redaka s početka i kraja razdoblja. Reci jesu li mjeseci uzastopni i postoje li praznine u brojčanim serijama. Objašnjenje i rezultate prikaži u razgovoru, bez programskog koda.

Očekujemo 120 različitih uzastopnih mjeseci od siječnja 2015. do prosinca 2024. Obje brojčane serije imaju vrijednost za svaki mjesec. Prazne oznake statusa u našoj tablici znače da dodatni status podatka nije naveden. U rječniku podataka opisani su stupci i jedinice.

Jedan redak odnosi se na jedan mjesec u Hrvatskoj. Anketni odgovori potrošača već su sažeti u pokazatelj. Zato iz ove tablice ne možemo opisivati razlike među kućanstvima. Za takvo pitanje trebali bismo podatke o pojedinim ispitanicima.

Dvije mjere, dva vremenska značenja

HICP je u tablici izražen godišnjom stopom promjene. Podatak za ožujak uspoređuje cijene s ožujkom prethodne godine. Saldo očekivanja nastaje iz odgovora o budućem kretanju cijena. Obje vrijednosti bilježimo u istom retku, ali one govore o različitim vremenskim usporedbama.

Usporedbom vrijednosti iz istog mjeseca opisujemo kako se mjere kreću zajedno. Ako nas zanima jesu li potrošači dobro predvidjeli buduću inflaciju, moramo odrediti koji kasniji ishod odgovara njihovu očekivanju. Treba razmotriti i što su mogli znati kada su odgovarali. Na radionici počinjemo jednostavnijom usporedbom vrijednosti iz istog mjeseca.

> Odaberi ožujak 2022. i objasni obje vrijednosti običnim jezikom. Uz svaku navedi jedinicu i vremensku usporedbu na koju se odnosi. Predloži zatim jedno pitanje na koje nam taj redak sam ne može odgovoriti, ali bi nam pomogao pogled na okolne mjesece.

Vrijedi se zadržati na tom jednom retku. Kad možete objasniti obje vrijednosti, bit će lakše čitati cijeli niz i procijeniti odgovara li AI-jev opis onome što podaci mjere.

Što podaci trebaju da bi postali korisni

Goldsmith-Pinkham u demonstraciji Large Datasets and Structured Databases pokazuje kako organizirani podaci i njihovi opisi olakšavaju istraživanje. Jedan od problema u njegovu primjeru nastaje zbog promjene identifikatora, što nalikuje stvarnoj promjeni u podacima dok se ne razumije njihova struktura. Poruka se odnosi i na male tablice: značenje podataka određuje koje su usporedbe opravdane.

Za naš skup već znamo obuhvat i značenje mjera. U drugom projektu trebat će provjeriti jesu li se kroz vrijeme mijenjali uzorak, anketno pitanje ili način mjerenja. Takva promjena može utjecati na usporedbu čak i kada tablica izgleda uredno. AI može pomoći pronaći i objasniti odgovarajuću dokumentaciju.

Zato zadatak „očisti podatke” često traži razgovor prije izvršavanja. Visoka vrijednost može biti upravo događaj koji želimo proučiti. Nedostajuća vrijednost i nula imaju različito značenje. U ovoj radionici zadržavamo izvorne brojčane vrijednosti i cijelo razdoblje, a uži odabir koristimo samo za jasno određenu usporedbu ili prikaz.

Kada AI stvara novu mjeru

Ako bismo kasnije analizirali medijske tekstove, mogli bismo zatražiti da AI svaki članak označi prema tonu. Tada njegov odgovor postaje istraživačka varijabla. Ludwig, Mullainathan i Rambachan u radu Large Language Models: An Applied Econometric Framework objašnjavaju zašto takvo mjerenje treba usporediti s validacijskim uzorkom. Pogreške u oznakama mogu utjecati na kasnije procjene odnosa.

Za početak odaberite nekoliko tekstova i dogovorite što biste nazvali zabrinutim tonom. Usporedite svoje oznake s AI oznakama i razgovarajte o neslaganjima. Tih nekoliko primjera služi učenju, a za istraživanje treba osmisliti zaseban validacijski uzorak i uzeti pogreške u obzir. To bi bio novi projekt. U našem CSV-u takvih oznaka nema.

Koliko posla prepustiti asistentu

Asistentu možete prepustiti pregled tablice ili izradu grafova. Prije nego što pokrenete zadatak, pokušajte predvidjeti dio rezultata koji možete zaključiti iz opisa podataka.

Koliko redaka treba imati godišnja tablica za deset godina? Koliko mjeseci ulazi u svaki prosjek? Kad dobijete rezultat, usporedite ga s onim što ste očekivali. Ako se razlikuje, zatražite objašnjenje prije nego što nastavite.

2.2 Izradite i objasnite prikaze

Dan 2, tema 2.2 · Vježba 2.2

Primjer iz radionice

Razgovor. Kako prikazati dvije mjere da se njihovo kretanje može usporediti?

Primjer. Zatražimo dva vremenska grafa sa zajedničkom osi mjeseci i godišnju tablicu prosjeka. Objasnimo što saznajemo iz grafa, a što iz tablice.

Isprobajte. Prilagodite prikaz svojem pitanju, primjerice izdvojite 2020.–2024. Objasnite koji se obrazac sada lakše vidi i zašto.

Naručite prikaz koji odgovara pitanju

Prije izrade grafa recite što želite vidjeti. Za pitanje o promjenama kroz vrijeme treba sačuvati redoslijed mjeseci. Za usporedbu godina može pomoći godišnji sažetak. Prikaz biramo prema pitanju koje nas zanima.

Naše dvije serije imaju različite jedinice. Prikazat ćemo ih u dva panela, jedan iznad drugoga, sa zajedničkom vremenskom osi. Tako možemo usporediti trenutke promjene uz zasebnu skalu svake mjere.

> Iz učitanog CSV-a izradi dva vremenska grafa za 2015.–2024., jedan iznad drugoga, sa zajedničkom osi mjeseci. Na prvom prikaži godišnju stopu HICP-a u postocima, a na drugom saldo očekivanih promjena cijena u bodovima. Dodaj jasne naslove i izvore Eurostat i DG ECFIN, s datumom preuzimanja 26. listopada 2026. Prikaži grafove i kratko objasni njihov sadržaj, bez programskog koda.

Pogledajte graf prije nego što pročitate AI-jevo objašnjenje. Što vam prvo privlači pažnju: nagli vrhunac, dulje razdoblje rasta ili dio u kojem se serije razilaze? Zatim pročitajte ponuđeni opis. Ako je alat istaknuo nešto drugo, razmislite koji je obrazac važniji za vaše pitanje.

Što dobivamo godišnjom tablicom

Godišnja tablica olakšava usporedbu 2021. i 2022. Za pitanje kada je promjena počela i koliko je trajala treba se vratiti mjesečnom grafu. Zato ćemo pripremiti oba prikaza.

> Napravi tablicu godišnjih prosjeka za obje mjere. Uz svaku godinu navedi broj mjeseci koji ulaze u prosjek. Prosjek HICP-a nazovi prosjekom mjesečnih godišnjih stopa, a saldo izrazi u bodovima. Prikaži dvije decimale. Zatim usporedi 2021. i 2022. i objasni što je godišnje sažimanje sakrilo u odnosu na mjesečni graf.

Za 2021. prosjek mjesečnih godišnjih stopa HICP-a iznosi približno 2,68 %, a prosjek salda 28,26 bodova. Za 2022. odgovarajuće su vrijednosti 10,63 % i 46,62 boda. Svaki prosjek obuhvaća dvanaest mjeseci. Godišnji prosjek stopa u ovoj tablici treba razlikovati od

godišnje promjene prosjeka samog indeksa cijena. Tu drugu veličinu računali bismo iz razina indeksa.

Zamislite da imate samo godišnju tablicu. Koji biste dio priče mogli ispričati, a za što bi vam nedostajali mjeseci? Vratite se grafu i pronađite promjenu koju godišnji prosjek skriva.

Promijenite jednu stvar i objasnite učinak

Za vlastiti pokušaj odaberite jednu promjenu prikaza. Možete izdvojiti kasnije razdoblje, jasnije označiti godine ili prilagoditi naslov pitanju koje postavljate. Prije izmjene recite što očekujete da će biti lakše vidjeti. Nakon nje usporedite prikaze.

> Izradi dodatnu verziju grafova samo za 2020.–2024. Zadrži iste definicije mjera. Cijeli izvorni skup ostaje dostupan za kasniju usporedbu. Objasni što uži vremenski prikaz ističe i koji se kontekst gubi izostavljanjem ranijih godina.

Izdvojeni prikaz obuhvaća 60 mjeseci. Može olakšati čitanje promjene, ali izbor početka i kraja utječe na dojam. Ako uspoređujete nekoliko grafova iste mjere, razgovarajte i o rasponu okomite osi. Jednaka skala olakšava procjenu veličine razlika između prikaza.

Udio čega?

Šikićev opis metode pokazuje kako širenje zbirke može promijeniti udjele u njoj. To je koristan primjer za čitanje grafova. Zamislite da prikupljate medijske tekstove o inflaciji. Njihov broj može rasti, a udio padati ako ukupan broj prikupljenih tekstova raste još brže. Promjena može nastati i zato što ste uključili novi portal.

Za takav graf pitajte: zanima li nas količina izvještavanja ili mjesto inflacije među svim temama? Uz udio treba znati što ulazi u nazivnik. U našoj godišnjoj tablici srodno je pitanje koliko mjeseci ulazi u svaki prosjek. Jednaki stupci ne jamče da sažimaju jednak obuhvat.

Što graf govori čitatelju

Goldsmith-Pinkham u demonstraciji From an Empty Folder to a Figure pokazuje kako uz AI od početne ideje dolazi do grafa. U našem su primjeru podaci već pripremljeni. Sada možemo pogledati je li prikaz koji smo zatražili doista koristan za pitanje kojim se bavimo.

Pokažite graf kolegi i pitajte što prvo primjećuje. Ako vidi nešto drukčije od onoga što ste željeli istaknuti, razmotrite naslov, oznake osi i popratno objašnjenje. Možda treba promijeniti i sam prikaz.

2.3 Ponovite analizu od početka

Dan 2, tema 2.3 · Vježba 2.3

Primjer iz radionice

Razgovor. Koliko naš opis odnosa ovisi o razdoblju koje promatramo?

Primjer. Iz cijelog CSV-a ponovno izdvojimo dvanaest vrijednosti HICP-a za 2022. Njihov zbroj iznosi 127,6, a prosjek približno 10,6333 %. Povežemo taj račun s godišnjom tablicom.

Isprobajte. Usporedite korelaciju za cijelo desetljeće i za dva petogodišnja razdoblja. Objasnite što se izgubi kada odnos opišemo samo jednim brojem.

Vratite se cijelom skupu

U prethodnom poglavlju možda ste prikazali samo 2020.–2024. Sada nam opet treba svih 120 mjeseci kako bismo usporedili ranije i kasnije razdoblje. To jasno navedite u novom upitu, da alat ne nastavi računati na prethodno izdvojenim podacima.

> Ponovno kreni od cijelog učitanog CSV-a. Prikaži svih dvanaest godišnjih stopa HICP-a za 2022., njihov zbroj i prosjek. Zatim izračunaj Pearsonovu korelaciju između dviju mjera iz istog mjeseca za 2015.–2024., 2015.–2019. i 2020.–2024. Uz svaki rezultat navedi broj mjeseci. Prikaži tablicu i objašnjenje postupka običnim jezikom, bez programskog koda.

Za 2022. zbroj dvanaest vrijednosti dijelimo s dvanaest i dobivamo približno 10,63 %. Tako možemo pratiti kako je nastao jedan rezultat godišnje tablice. Kod složenijeg izračuna zatražite objašnjenje onoga što se uspoređuje i načina na koji su opažanja odabrana.

Što korelacija sažima

Pearsonova korelacija opisuje linearnu povezanost parova vrijednosti. U našoj spremljenoj verziji podataka iznosi približno 0,6985 za 2015.–2024., uz 120 mjeseci. Za 2015.–2019. iznosi 0,8279, a za 2020.–2024. 0,5342, uz po 60 mjeseci. To su opisni rezultati iz referentne analize.

Prema ovom pokazatelju povezanost je jača u ranijem podrazdoblju. Jedna korelacija za cijelo desetljeće skriva tu razliku. Vratite se grafovima i pogledajte kada su se serije kretale slično, a kada su se razilazile.

Iz same razlike među korelacijama ne možemo zaključiti da se dogodio strukturni lom ili da je jedna mjera promijenila drugu. Na rezultat mogu utjecati zajednički šokovi, vremenska ovisnost i odabrano razdoblje. Za provjeru tih objašnjenja treba zasebna analiza. Zasad možemo obrazložiti zašto bi tu razliku vrijedilo dalje istražiti.

Kada više izračuna postane novo istraživanje

AI nam olakšava naručivanje dodatnih usporedbi. Možemo zatražiti drukčiji početni mjesec, kraći raspon ili pomicanje jedne serije u odnosu na drugu. Svaka od tih odluka mijenja pitanje koje broj sažima. Prije izračuna objasnite zašto vas određena promjena zanima.

Ako isprobavate različita razdoblja kako biste upoznali podatke, predstavite taj rad kao istraživanje obrazaca. Odabir samo najjače korelacije nakon mnogo pokušaja ne pokazuje da je upravo taj odnos najvažniji. Za prognozu biste trebali odrediti cilj i vremenski horizont te odvojiti razdoblje na kojem procjenjujete uspješnost.

Goldsmith-Pinkham u raspravi o AI one-shot papers upozorava da automatizirana izvedba može posezati za poznatim metodama koje i dalje zahtijevaju istraživačku prosudbu. Naš je primjer jednostavniji, ali otvara isto pitanje: što bi nam dodatna metoda omogućila zaključiti i zašto su njezine pretpostavke ovdje uvjerljive?

> Predloži jedno moguće objašnjenje razlike među podrazdobljima i jedno alternativno objašnjenje. Za svako reci koje dodatne podatke ili usporedbe trebamo da bismo ih mogli razlikovati. Poveži prijedloge s onim što smo stvarno vidjeli na grafovima.

Kako provjeriti provjeru

U skici modela provjere Šikić razmatra i pogreške onoga tko provjerava tuđi rad. To je teorijsko polazište, a ne procjena pouzdanosti pojedinog alata. Na radionici ga možemo pretvoriti u mali pokus. U kopiji tablice namjerno promijenite jedan godišnji prosjek, ostavite druge vrijednosti točnima i zatražite provjeru prema izvornom CSV-u.

Je li alat pronašao pogrešku? Je li točan rezultat proglasio pogrešnim? Pogledajte je li ponovno izračunao vrijednosti ili samo komentirao tablicu. Jedan pokušaj ne mjeri opću pouzdanost, ali pokazuje što podrazumijevamo pod provjerom. Za nastavak rada vratite se ispravnoj tablici i izvornim podacima.

Možemo li objasniti dobiveni rezultat?

U svojem primjeru suradnje na empirijskoj analizi Goldsmith-Pinkham opisuje slučaj u kojem je zapis rada tvrdio da je analiza provedena, iako nije bila. Zato uz objašnjenje postupka treba pogledati i stvarni rezultat. U našoj vježbi to znači otvoriti tablicu ili graf i povezati ih s pitanjem, mjerama i razdobljem koje smo zadali.

Odaberite rezultat koji još ne možete dobro objasniti. Što vam točno nedostaje? Treba li razjasniti vremensku usporedbu, ponoviti račun ili pronaći druge podatke? Riješite to prije nego što zatražite novu tablicu. Time smanjujete dug provjere s početka priručnika.

Sačuvajte podatke, odabrane prikaze i tablicu rezultata. Za potpuno ponavljanje računalnog postupka treba i datoteka s uputama koje računalo može ponovno izvršiti. Zatražite je od alata. Samo ponovno slanje istog upita može dati drukčiji postupak. Kolegi koji želi ponoviti vaš rad objasnite što ste sačuvali i kako to može upotrijebiti.

2.4 Napišite i uredite zaključak

Dan 2, tema 2.4 · Vježba 2.4

Primjer iz radionice

Razgovor. Što biste o svojem nalazu objasnili osobi koja nije sudjelovala u analizi?

Primjer. Napišemo vlastito tumačenje jednoga grafa, zatražimo komentare na argument i odlučimo kako ćemo ga preraditi.

Isprobajte. Sastavite oko 150 riječi odgovora na svoje pitanje. Uz graf pokažite broj koji podupire glavni nalaz i objasnite jedno otvoreno pitanje. Kolegi obrazložite jednu odluku pri uređivanju.

Pisanje razvija razumijevanje

Pokušajte napisati što vaš graf pokazuje. Možda ćete zapeti na jednostavnom pitanju: zašto ste odabrali baš to razdoblje ili što ta brojka govori o inflaciji? Takav zastoj otkriva što još treba razjasniti. Zato prvo napišite vlastito tumačenje, makar bilo nespretno.

Goldsmith-Pinkham u tekstu Writing & Thinking with AI Assistance razlikuje pomoć u rutinskom pisanju od prepuštanja oblikovanja argumenta. Predlaže i način rada u kojem asistent komentira nacrt, a autor ga zatim sam prerađuje. To ćemo isprobati u završnoj vježbi. Jezičnu pomoć možete zatražiti kada ste zadovoljni objašnjenjem nalaza.

Za naš zaključak počnite odgovorom na odabrano pitanje. Ako vas zanimaju razlike među razdobljima, istaknite tu usporedbu. Ako ste proučavali promjene tijekom 2021. i 2022., usmjerite tekst na te godine. Ne trebate prepričati svaku tablicu koju ste proizveli.

> Pročitaj moj nacrt zaključka i daj komentare bez prepisivanja. Izdvoji mjesto na kojem argument nije jasan, pitanje na koje još nisam odgovorio i tvrdnju kojoj treba bolje obrazloženje. Za svaki komentar objasni zašto je važan za moje istraživačko pitanje. Zatim pričekaj moju preradu.

Odaberite komentar koji vam pomaže popraviti tekst. Ako ne razumijete što bi se predloženom promjenom dobilo, zatražite objašnjenje. Komentar koji ne odgovara vašem pitanju ili analizi možete odbaciti. U oba slučaja pokušajte objasniti svoju odluku.

Povežite pitanje, graf i nalaz

Počnite od onoga što ste uspoređivali. Zatim pokažite važan obrazac na grafu ili broj iz tablice i objasnite što govori o pitanju. Recite i što je ostalo otvoreno. Čitatelj bi trebao moći pratiti zaključak bez pristupa cijelom razgovoru s alatom.

Za usporedbu godišnjih sažetaka možemo napisati sljedeći odlomak.

> U hrvatskim podacima prosjek mjesečnih godišnjih stopa HICP-a porastao je s 2,68 % u 2021. na 10,63 % u 2022. U istim je godinama prosjek salda očekivanih promjena cijena porastao s 28,26 na 46,62 boda. Godišnji sažeci tako pokazuju rast obiju mjera, dok mjesečni grafovi omogućuju detaljniji opis njihova kretanja. Iz te usporedbe još ne možemo odrediti uzrok promjene ni uspješnost predviđanja buduće inflacije.

Odlomak opisuje promjenu između dviju godina. Ako vas zanima povezanost među razdobljima, oslonite se na korelacije iz prethodnog poglavlja i objasnite što one uspoređuju. U zaključak uključite rezultate koji odgovaraju na vaše pitanje.

Jezična pomoć i vlastiti glas

Kad znate što želite reći, zatražite pomoć s jezikom. Asistent može skratiti predugu rečenicu, predložiti bolji redoslijed ili pomoći pri pisanju na jeziku koji vam nije prvi. Pročitajte prijedlog i procijenite izražava li jasno ono što ste mislili.

> Predloži jezičnu doradu ovog odlomka. Zadrži moje tumačenje, brojke i nazive mjera. Objasni jednu važnu promjenu koju predlažeš. Ako ti sadržaj nije jasan, najprije me pitaj što želim reći na tom mjestu.

Pazite na razliku između inflacije i razine cijena, salda i postotka te očekivanja i percepcija. Birajte izraze koje biste upotrijebili i kada kolegi usmeno objašnjavate nalaz. Ako rečenicu morate nekoliko puta pročitati da biste je razumjeli, pokušajte je pojednostavniti.

Pokažite kolegi završni graf i objasnite glavni nalaz bez čitanja odlomka. Njegova pitanja mogu otkriti gdje tekst treba dopuniti. Ako ste nakon AI komentara promijenili argument, recite što ste promijenili i zašto.

Što ostaje kad zatvorite razgovor

Liu i suradnici u eksperimentima s razlomcima i razumijevanjem pročitanog nalaze slabiji samostalan učinak nakon uklanjanja AI pomoći nego u kontrolnoj skupini. Njihov rad AI Assistance Reduces Persistence and Hurts Independent Performance ne ispituje pisanje ekonomskih radova ni dugoročno učenje. Ipak, daje povod da razdvojimo dovršen zadatak od onoga što smo naučili.

Zatvorite razgovor i uz svoj graf objasnite zašto ste odabrali baš tu usporedbu. Zatim odgovorite na novo pitanje kolege, primjerice što bi se izgubilo prikazom samo godišnjih prosjeka. Ako zapnete, vratite se objašnjenju ili zatražite malu pomoć prije gotovog odgovora. Koji biste dio analize sada mogli sami objasniti u novom zadatku?

Od zaključka do sljedećeg pitanja

Naša analiza može potaknuti pitanje o ulozi medija ili komunikacije HNB-a. Za takav projekt trebali bismo povezati podatke o cijenama i očekivanjima s novom zbirkom tekstova. Goldsmith-Pinkhamova demonstracija pretvaranja objava u strukturirane podatke pokazuje kako AI može olakšati takav početak istraživanja.

Za temu medija najprije odaberite mali skup članaka i pitanje koje njima želite istražiti. Dogovorite što znači medijska pažnja ili ton, razmotrite nekoliko primjera zajedno i usporedite vlastita tumačenja s klasifikacijom alata. Tek kada razumijete tu mjeru, ima smisla širiti zbirku i povezivati je s drugim podacima. Odnos koji tada pronađete i dalje traži zasebno objašnjenje prije uzročnog zaključka.

Na kraju usporedite iskustva. Što vam je alat olakšao? Oko koje ste odluke morali najviše razmišljati? Odaberite jedno pitanje kojem biste se htjeli vratiti nakon radionice.