EIZ / PRIRUČNIK ZA SAMOSTALNO ČITANJE

istraživanje uz umjetnu inteligenciju

Prošireni tekst obaju dana radionice

Izvorni materijal: Luka Šikić, UNICATH

Revidirano izdanje / 26. listopada 2026.



OSAM POGLAVLJA / IZVORI · ANALIZA · PISANJE

Materijali za radionicu i samostalno čitanje.

Sadržaj

Kako čitati ovaj priručnik 3

Prvi dan: istraživanje i strukturiranje 4

1.1 Kako razumjeti AI asistenta 4

1.2 Pretraživanje literature s Perplexityjem 7

1.3 Dubinsko istraživanje s Gemini Deep Research 10

1.4 Od bilješki do nacrta rada s Claudeom 13

Drugi dan: kodiranje i pisanje 16

2.1 Agentsko kodiranje i provjerljiva analiza 16

2.2 Rad u editoru: Copilot, RStudio i Positron 20

2.3 Bilježnice, eksploracija i reproducibilnost 23

2.4 Pisanje i uređivanje akademskog teksta 26

Poveznice u sadržaju i bočne oznake PDF-a vode na poglavlja. Podcrtane poveznice uz tvrdnje vode na izvorne dokumente. Tekst možete pretraživati i označavati.

Kako čitati ovaj priručnik

Ovaj priručnik vraća opširniji tekst izvornih dvaju dana radionice kao dodatno čitanje uz kratke nastavne stranice i radne listove. Zadržava osam izvornih tema, objašnjenja kroz primjere, obrasce upita i pitanja za samostalni rad. Tekst je uredničkи prerađen: uklonjena su ponavljanja, ispravljene nepotkrijepljene tvrdnje i ažurirana objašnjenja alata. Ovo je revidirano izdanje, a ne doslovna arhivska kopija.

Izvorni materijal: Luka Šikić, UNICATH, tekstovi „Dan 1: Istraživanje i strukturiranje” i „Dan 2: Kodiranje i pisanje” iz repozitorija EIZ-radionica. Revizija sadržaja: 26. listopada 2026. Datum revizije nije datum održavanja nove radionice. Prerađeno izdanje pripremljeno je uz AI pomoć, uz dokumentirane izvore i provjeru analitičkog postupka.

Prvi dio vodi od razumijevanja jezičnih modela preko provjere izvora do plana rada. Drugi povezuje agentsku pomoć, rad u editoru i bilježnicama s analizom i pisanjem. Možete čitati redom ili otvoriti poglavlje koje odgovara zadatku na kojem radite. Vježbe na kraju poglavlja služe samostalnom produbljivanju; ne dodaju nove obvezne predaje osam radnih blokova radionice.

Numerički primjeri koriste zamrznuti hrvatski skup za 2015.–2024., preuzet 26. listopada 2026. Podaci u nastavnom paketu, skripte i referentni izlazi omogućuju provjeru brojeva. Nazivi alata ilustriraju načine rada. Dostupnost funkcija provjerena je prema službenoj dokumentaciji na datum revizije; računi, sučelja i uvjeti mogu se promijeniti. Osnovni ishodi radionice ne ovise o plaćenoj funkciji.

Uz čitanje držite otvorene rječnik podataka, početnu skriptu i vlastite bilješke. Za svaku važnu tvrdnju pitajte se što je podupire. Za svaki postupak pitajte se možete li ga objasniti i ponovno izvesti. Tako priručnik postaje pomoć u radu, a ne još jedan tekst koji samo prelistate.

Prvi dan: istraživanje i strukturiranje

1.1 Kako razumjeti AI asistenta

Od prazne stranice do istraživačkog pitanja

Zamislite da trebate napisati seminarski rad. Imate temu, nekoliko otvorenih kartica i bilješke iz predavanja, ali još ne znate kojim pitanjem započeti. Traženje literature, povezivanje pojmova i organiziranje bilježaka oduzimaju vrijeme prije nego što uopće počnete analizirati podatke. AI može pomoći u svakom od tih koraka. Korist nastaje kada njegov prijedlog pretvorite u nešto što možete provjeriti: pitanje s jasnim opsegom, izvor s poznatim autorom, skriptu koja se može pokrenuti ili odlomak čije tvrdnje odgovaraju dokazima.

U izvornom tekstu radionice taj je put prikazan kroz Perplexity, Gemini i Claude, a zatim kroz programske asistente i bilježnice. Zadržavamo taj slijed jer odgovara istraživačkom procesu. Nazivi proizvoda služe kao primjeri; njihove se mogućnosti preklapaju. Ne morate imati račun u svakom alatu da biste naučili pronaći dokaz ili objasniti rezultat.

Radionicu povezuje hrvatski primjer. Promatramo mjesečnu ostvarenu inflaciju i anketni pokazatelj očekivanih promjena cijena od 2015. do 2024. To je namjerno ograničen zadatak: dvije mjere, 120 mjeseci i postupak koji možete ponovno izvesti. Šire pitanje o ulozi medija i komunikacije HNB-a ostaje motivacija za nastavak istraživanja. Ovaj paket ne sadrži medijski korpus ni indeks medijske pažnje i ne prikazuje rezultate takvog istraživanja.

Kako jezični model oblikuje odgovor

Veliki jezični model tijekom treniranja uči obrasce u podacima. U razgovoru koristi naučene parametre i dostupan kontekst kako bi oblikovao nastavak teksta. Tekst obrađuje u tokenima: dijelovima riječi, riječima ili drugim jedinicama. Broj tokena po riječi ovisi o jeziku i tokenizatoru, pa jednu procjenu za engleski ne treba primijeniti na hrvatski seminarski rad.

Pojednostavljeno, model procjenjuje raspodjelu $P(t_k \mid t_1, \ldots, t_{k-1}; \theta)$: vjerojatnosti mogućih sljedećih tokena uz prethodni kontekst i naučene parametre. Način odabira nastavka može uključiti uzorkovanje. Vjerojatnost tokena nije vjerojatnost da je tvrdnja istinita. Model može proizvesti vrlo uvjerljivu rečenicu čiji se sadržaj ne može potvrditi.

Korisna je analogija s dobro načitanim suradnikom koji brzo predlaže formulacije. Ipak, analogija ima granice. Model nema provjerljivo osobno iskustvo istraživanja koje opisuje. S druge strane, aplikacija s pristupom alatima može stvarno otvoriti dokument, pretražiti web ili izvršiti kod. Zato treba razlikovati tri situacije: odgovor iz naučenih obrazaca, odgovor uz dohvaćene izvore i rezultat izvršenog izračuna. U svakom slučaju tražite trag koji odgovara vrsti tvrdnje.

Kontekstni prozor određuje koliko sadržaja model može obraditi u pojedinom koraku. Dug razgovor, projektna zbirka datoteka i aktivni kontekst nisu ista stvar. Aplikacija može

sažeti ranije poruke ili dohvatiti samo dijelove dokumenata. Učitavanje dvadeset radova zato ne jamči da je svaka rečenica iz svakog rada uključena u svaki odgovor. Posebno navedite datoteku, odjeljak ili tablicu na koju se pitanje odnosi.

Temperatura, kada je dostupna, utječe na način uzorkovanja. Ni niska temperatura ni način rada s duljim računanjem nisu potvrda istinitosti. Korisniku je korisnije provjeriti citat i rezultat nego nagađati što se dogodilo u unutarnjem postupku modela. Prikaz plana ili objašnjenja također nije potpuni zapis svih internih operacija.

Tri vrste uvjerljive pogreške

Izmišljena referenca može sadržavati stvarno prezime autora, uvjerljiv naslov i nepostojeći DOI. Ako je citat sastavljen uredno, lakše ga je zamijeniti s provjerenim izvorom. Postojanje rada provjerite kod izdavača ili u bibliografskoj bazi, a zatim pročitajte dio koji navodno podupire tvrdnju.

Pogrešno protumačen broj može potjecati iz stvarne tablice. Primjerice, vrijednost salda očekivanja 40 ne znači da potrošači očekuju inflaciju od 40 posto. To je druga mjera, s drugom konstrukcijom i jedinicom. Provjera aritmetike bez provjere definicije varijable nije dovoljna.

Kod koji radi pogrešnu stvar može se izvršiti bez upozorenja. Spajanje dviju tablica prema rednom broju retka umjesto prema mjesecu može povezati različite datume. Automatsko uklanjanje praznina može promijeniti uzorak. Zato uz izlaznu tablicu provjeravamo ulaz, broj opažanja i pravilo obrade.

Za demonstraciju pogreške nije potrebno čekati da AI nešto izmisli. Uzmite tvrdnju „pozitivna korelacija dokazuje da očekivanja uzrokuju inflaciju” i usporedite je s onim što izračun doista pokazuje. Time vježbate istu vještinu čak i kada model ponudi besprijekoran odgovor. Namjerno pogrešan primjer treba jasno označiti, kako ga netko ne bi kasnije preuzeo kao nalaz.

Birajte mogućnost, a zatim alat

Za prvo upoznavanje teme koristan je sustav koji pretražuje izvore i daje poveznice. Za usporedbu više pročitanih radova koristan je rad s dokumentima. Za izračun je potrebno okruženje koje izvršava kod i omogućuje njegov izvoz. Za uređivanje teksta potrebni su jasni komentari i mogućnost usporedbe inačica. Jedan proizvod može pokrivati nekoliko tih potreba.

Službena dokumentacija sada opisuje pretraživanje i istraživačke postupke u više aplikacija, uključujući ChatGPT, Gemini i Claude Projects. Pristup ovisi o računu, planu i postavkama ustanove. U ovom izdanju ne navodimo rang-listu „najboljih modela”, cijene ni zajamčene dnevne kvote. Prije nastave provjerite funkciju koju ćete stvarno koristiti.

Za usporedbu dvaju dostupnih alata pripremite isti mali zadatak: isti odlomak, tri ista izvora i isto pitanje. Usporedite točnost, sljedivost, razumljivost i vrijeme potrebno za provjeru. Dulji odgovor ili više citata nisu sami po sebi bolji rezultat. Ako alat ne može otvoriti izvor, bilješka „nemam pristup punom tekstu” korisnija je od uvjerljivog nagađanja.

Integritet i odgovornost

Izvorna podjela na zelenu, žutu i crvenu zonu može pomoći u razgovoru o riziku, ali nije zamjena za pravila kolegija. Pravopisna pomoć obično mijenja manje istraživačkog sadržaja od izrade cijelog argumenta. Ipak, ni jednu od tih uporaba ne proglašavamo univerzalno dopuštenom. Provjerite upute zadatka i navedite opseg pomoći kada je to traženo.

Manji rizik imaju prijedlog ključnih riječi, objašnjenje poruke o pogrešci i komentar jasnoće vašeg odlomka. Veću pažnju traže sažimanje nepročitanog rada, izbor metode, prerada argumenta i generiranje koda koji mijenja podatke. Izmišljeni izvori, prikrivanje nedopuštene pomoći i predstavljanje neizvedene analize kao vlastitog rezultata nisu prihvatljiv istraživački postupak. Izjava o uporabi AI-ja ne ispravlja takve probleme.

Ne unosite identifikacijske podatke ispitanika, povjerljive intervjue ili neobjavljene materijale u vanjsku uslugu bez odgovarajućeg dopuštenja. Plaćeni račun sam po sebi nije potvrda prikladnosti za te podatke. Za ovu radionicu dovoljan je javni skup službenih agregiranih podataka.

Zapis uporabe može biti jednostavan: datum, alat, zadatak, prihvaćeni prijedlog i način provjere. Primjerice: „AI je predložio oznake osi; usporedio/la sam ih s rječnikom podataka i promijenio/la oznaku očekivanja iz postotka u saldo.” Citiranje empirijske tvrdnje vodi na njezin izvor; bilješka o uporabi alata objašnjava kako ste radili.

Pokušajte sami

Napišite jedno pitanje o inflaciji i unaprijed odredite što bi bio provjerljiv odgovor. Zatim zatražite prijedlog od dostupnog asistenta. Razdvojite rečenice u tri skupine: tvrdnje koje trebaju izvor, prijedloge istraživačkog postupka i pitanja na koja još nema odgovora. Provjerite jednu tvrdnju u izvornom dokumentu i jednu brojku u podacima. Na kraju vlastitim riječima objasnite što vam je model olakšao i koju ste odluku ipak morali donijeti sami.

1.2 Pretraživanje literature s Perplexityjem

Od popisa poveznica do početne sinteze

Prisjetite se kako ste zadnji put tražili literaturu za seminarski rad. Otvorili ste tražilicu, upisali nekoliko pojmova i dobili mnogo rezultata. Neki su bili iza pristupne barijere, neki se nisu odnosili na vašu temu, a nakon nekoliko otvorenih radova postalo je teško pratiti tko govori što. AI pretraživanje može pomoći u početnom snalaženju: predložiti pojmove, sažeti pronađene stranice i povezati tvrdnje s izvorima.

Zadržimo izvornu analogiju knjižnice. Katalog vas usmjerava prema policama; asistent pokušava donijeti i sažetak pronađenog materijala. Sažetak je koristan samo ako možete ustanoviti što je stvarno pročitano. Asistent može zamijeniti sažetak rada s cijelim radom, povezati citat s preširokom tvrdnjom ili zanemariti izvor do kojeg nije uspio doći.

Perplexity je u ovom poglavlju primjer takvog rada. To više nije granica između njega i svih drugih razgovornih sustava: i drugi proizvodi nude web pretraživanje i izvore. Dohvaćanje sadržaja i njegovo korištenje pri generiranju odgovora često se opisuje pojmom RAG. Dohvaćeni dokumenti mogu poboljšati utemeljenost odgovora, ali sam postupak ne jamči potpunost, točnost citata ni kvalitetu uključenih studija.

Tri upita koji postupno razjašnjavaju temu

Prvi upit iz izvornog materijala ostaje dobar primjer početne neodređenosti:

> Inflacija Hrvatska.

Ovakav upit ne govori tražite li najnoviji statistički podatak, objašnjenje pojma ili empirijsku literaturu. Mješavina vijesti, službenih podataka i općih objašnjenja može biti korisna za orijentaciju, ali teško ju je pretvoriti u pregled literature bez dodatnog usmjeravanja.

Sljedeći korak određuje predmet interesa:

> Koji čimbenici mogu biti povezani s percepcijom inflacije kod kućanstava u europskim zemljama? Pronađi istraživanja i za svako navedi autora, naslov, godinu i poveznicu na izvor. Odvoji radove od novinskih prikaza.

Sada je jasnije da vas zanima percepcija, a ne samo promjena indeksa cijena. Ipak, percepcija prošlih promjena i očekivanje budućih promjena nisu isti pojam. U nastavku razgovora razjasnite koji konstrukt želite proučavati. Najprecizniji upit treba proizlaziti iz vašeg pitanja, a ne iz želje da zvuči tehnički složeno.

> Find empirical studies on media coverage and households' inflation expectations in European economies, published from 2015 onward. Separate studies of perceptions from studies of expectations. For each candidate, report the exact title, authors, publication type, data, method and source URL. State whether you accessed the full text or only an abstract. Do not infer findings from the title.

Ovaj upit zadržava temu izvornog materijala i dodaje provjerljive zahtjeve. Engleski pojmovi mogu olakšati pretraživanje međunarodne literature, ali pretragu treba dopuniti hrvatskim izrazima i lokalnim izvorima. Preuski vremenski filtar može isključiti temeljni teorijski rad. Stoga noviju empirijsku literaturu i teorijske početne radove možete tražiti odvojeno.

Protokol trostruke provjere

Prva provjera je postojanje. Otvorite stranicu rada kod izdavača, institucionalni repozitorij ili bibliografski zapis. Usporedite naslov, autore, godinu i identifikator. DOI koji se otvara nije dovoljan ako vodi na drugi članak. Ako ne možete doći do punog teksta, to označite umjesto da prepričavate zaključke koje niste pročitali.

Druga provjera je potpora tvrdnji. Pronađite odjeljak, tablicu ili stranicu koji odgovaraju rečenici koju želite napisati. Studija može opisivati povezanost, a AI sažetak uzročnost. Može proučavati određenu zemlju, skupinu ispitanika ili informacijski eksperiment, dok sažetak govori o svim kućanstvima. Zabilježite te granice uz sam izvor.

Treća provjera je vrsta i kvaliteta izvora. Recenzirani članak, radni materijal središnje banke, metodološki priručnik i novinski tekst imaju različite namjene. Institucionalni ugled ne znači da je svaki dokument recenzirani znanstveni rad. Ni recenzija sama po sebi ne potvrđuje da je metoda prikladna za vaše pitanje. Procijenite podatke, dizajn, ograničenja i relevantnost.

Primjer za naš slučaj jest članak Meylera i Reiche o percepcijama i očekivanjima u ECB Economic Bulletinu. Koristan je za razumijevanje razlike između kvalitativnih i kvantitativnih mjera. Ne potvrđuje numerički rezultat naše hrvatske analize za cijelo razdoblje 2015.–2024. Jedan izvor može dobro podupirati definiciju, a ne podupirati vlastiti empirijski nalaz.

Od pronađenog rada do dokaznog zapisa

Za svaki od tri izvora potrebna radionici napišite kratak zapis: tvrdnja koju izvor podupire, puni bibliografski podaci, poveznica, mjesto u tekstu, vaš sažetak i jedno ograničenje. Tako nastaje pregled koji možete ponovno otvoriti kada budete pisali. Sam popis referenci bez tih bilježaka lako postaje zbirka naslova koje više ne povezujete s argumentom.

Razmislite o rečenici „potrošači očekuju rast inflacije”. Prvo provjerite što točno pita anketa. Pitanje o promjenama cijena u sljedećih dvanaest mjeseci u odnosu na proteklih dvanaest mjeseci nije zahtjev za brojčanom prognozom godišnje stope inflacije. Dokazni zapis treba sačuvati tu razliku, inače će se pogreška prenositi iz pregleda literature u analizu i zaključak.

Ponovljeno pojavljivanje istog autora u rezultatima može biti trag za daljnje čitanje. Nije dokaz važnosti samo po sebi: pretraživač može više puta pronaći isti popularni izvor ili njegove novinske prikaze. Pratite reference unatrag i novije citate unaprijed. Vodite bilješku o korištenim pojmovima, datumu pretrage i kriterijima odabira.

Obrasci za nastavak pretraživanja

Za metodološki pregled pitajte koje se metode koriste za konkretno pitanje i što omogućuje njihovu interpretaciju. Nemojte unaprijed tražiti usporedbu OLS-a, IV-a, DiD-a i RDD-a ako još ne znate kakvi podaci postoje. Bolje je zatražiti odnos između pitanja, dizajna i pretpostavki u svakom pronađenom radu.

Za teorijski okvir tražite definiciju mehanizma, njegove pretpostavke i predviđanja koja bi se mogla razlikovati od alternativnih objašnjenja. Pojmovi poput racionalne nepažnje i sporog usvajanja informacija mogu biti korisni za temu očekivanja. Nije dovoljno samo uvrstiti njihova imena u uvod; potrebno je pročitati izvor i objasniti što bi teorija značila za vaše mjere.

Za pregled podataka zatražite instituciju, šifru skupa, jedinicu, frekvenciju, obuhvat i uvjete pristupa. Za provjeru tvrdnje tražite i dokaze koji joj ne idu u prilog. Na primjer:

> Koji nalazi ograničavaju tvrdnju da intenzivnije medijsko izvještavanje povećava inflacijska očekivanja? Razlikuj opisnu povezanost od učinka identificiranog istraživačkim dizajnom. Navedi mjesto u svakom izvoru.

Ako naiđete na nepoznatu kraticu, poput IAG u starom nastavnom primjeru, nemojte pretpostaviti njezino značenje. Pronađite definiciju u radu, pravilo izračuna i izvor podataka. U ovom paketu ne postoji potvrđena definicija takvog indeksa. Njegovo mjesto ne popunjavamo značenjem iz drugog područja.

Organizacija i pristup

Perplexityjevi Spaces služe organiziranju razgovora i materijala po temama. Za nastavni zadatak korisno je odvojiti provjerene bilješke od početnih odgovora. Zajednički prostor olakšava suradnju, ali ne čini izvor provjerenim i ne zamjenjuje vlastitu spremljenu bibliografiju.

Filtri izvora i nazivi načina pretraživanja mogu se mijenjati. Oznaka „academic” nije jamstvo da je svaki rezultat recenziran. Jednako tako, Google Scholar ili specijalizirana baza ne jamče iscrpnost samo zato što ste ih otvorili. Za sustavni pregled potreban je unaprijed opisan postupak pretrage i odabira. Za ovu radionicu radimo ograničenu, dokumentiranu početnu pretragu.

Vježba za samostalno čitanje

Odaberite pitanje iz radionice ili vlastitu temu. Sastavite tri upita s rastućom preciznošću, izdvojite pet kandidata i detaljno provjerite tri. Za svaki ispunite dokazni zapis. Zapišite i jedan odbačeni izvor te razlog odbijanja. Moguće teme su očekivanja i inflacija, digitalizacija poduzeća, nejednakost ili učinci fiskalnih mjera; nijedna od njih unaprijed ne pretpostavlja smjer rezultata.

Usporedite početni AI sažetak s vlastitim bilješkama. Koju ste tvrdnju suzili? Koji je izvor bio relevantan, ali nedostupan? Što još nedostaje? Vježba završava kada možete objasniti izbor izvora, a ne kada alat proizvede dovoljno dug popis. Ako nemate pristup AI pretrazi, isti postupak provedite ručno s početnim izvorima radionice.

1.3 Dubinsko istraživanje s Gemini Deep Research

Kada jedan odgovor nije dovoljan

Što ako ste na početku istraživanja i trebate razumjeti cijelo područje? Kratak odgovor može vam pomoći pronaći pojam ili rad. Za usporedbu teorijskih objašnjenja, vrsta podataka i otvorenih pitanja treba vam organiziraniji pregled. Tu je koristan istraživački način rada koji planira više pretraga, prikuplja izvore i predlaže njihovu sintezu.

Izvorni materijal uspoređivao je brz upit s pitanjem lokalnom vodiču, a dubinsko istraživanje s naručivanjem opširnog izvješća. Analogija je korisna za razlikovanje zadataka, ali je ne treba pretvoriti u trajnu podjelu proizvoda. Isti alat može nuditi oba načina. Opširnije izvješće nije automatski potpunije ili točnije; može samo uvjerljivije prikriti praznine.

U ovom poglavlju zadržavamo Gemini Deep Research kao demonstracijski primjer. Prema Googleovim uputama, možete odabrati izvore, priložiti materijale i urediti predloženi plan prije pokretanja istraživanja. Dostupnost povezanih izvora ovisi o računu i postavkama. Taj izbor je važniji od pamćenja položaja gumba koji se može promijeniti do sljedeće izvedbe radionice.

Istraživački plan je vaš dokument

Prije pokretanja napišite što trebate znati. Razdvojite definicije, empirijske nalaze, metodološka pitanja i podatke. Zatim odredite obuhvat: zemlje, razdoblje objavljivanja, populaciju i jezike. Ako tražite noviju literaturu, dopustite zasebno navođenje starijih teorijskih radova kako vremenski filtar ne bi uklonio temeljne pojmove.

Slab početni zahtjev iz izvornog teksta glasi:

> Napiši pregled literature o inflaciji.

On ne kaže trebate li udžbeničko objašnjenje, pregled prognoziranja ili raspravu o očekivanjima. Sljedeći primjer zadržava izvorni interes za medije, ali bolje odvaja ono što tražimo od onoga što već znamo:

> Pripremi plan pregleda empirijske literature o medijskom izvještavanju i inflacijskim očekivanjima kućanstava u europskim zemljama. Glavni obuhvat su radovi objavljeni od 2010. nadalje; temeljne teorijske radove navedi zasebno. Organiziraj pregled prema mjerenju očekivanja, mjerenju medijske pažnje, istraživačkom dizajnu i ograničenjima.
>
> Za svaki rad navedi izvor, uzorak, razdoblje, mjere, metodu i glavni nalaz. Označi imaš li puni tekst. Razlikuj korelaciju, prognozu i uzročni zaključak. Ako podatak ne možeš provjeriti, označi ga kao nepoznat. Najprije pokaži plan; nemoj pretpostaviti da imamo medijski korpus.

Pogledajte kako zahtjev određuje rezultat. Ne traži određeni zaključak ni „dokaz” željene hipoteze. Ne dopušta da nepoznat uzorak bude popunjen izmišljenim brojem. Od agenta traži strukturu usporedivih zapisa, a ne samo elegantan pregled. I dalje morate provjeriti pridržava li se tih uputa.

Pregledajte predloženi plan prije izvršavanja. Ako se većina prostora troši na povijest središnjih banaka, a vi trebate usporediti mjere očekivanja, promijenite raspored. Ako nedostaje odjeljak o hrvatskim izvorima, dodajte ga. Ako plan predviđa procjenu učinka medija na temelju podataka koje nemate, zaustavite taj korak i razjasnite što bi trebalo prikupiti.

Što može nedostajati u dugom izvješću

Prvo ograničenje jest pristup izvorima. Alat može pronaći naslov ili sažetak, ali ne i tekst iza pretplate. Može koristiti javnu radnu verziju umjesto kasnije objavljene verzije. Institucionalni pristup koji imate u svom pregledniku ne prenosi se automatski na alat. Za važan rad sami provjerite verziju dokumenta i dostupnost metodoloških dodataka.

Drugo ograničenje jest dubina metodološkog čitanja. Rečenica „autori koriste regresijsku analizu” ne govori kako je izabran uzorak, koje su varijable uključene ili što omogućuje uzročnu interpretaciju. Tražite konkretnu specifikaciju i argument autora, zatim pročitajte odgovarajući odjeljak. Ako izvješće navodi samo naziv metode, to je polazna bilješka, a ne završena kritička evaluacija.

Treće ograničenje jest obuhvat pretrage. Odsutnost hrvatskog rada iz izvješća ne znači da takav rad ne postoji. Mogu nedostajati drugi jezici, radovi bez javnog punog teksta ili termini drukčiji od onih u upitu. Pregled koji priprema AI nije samim time sustavni pregled literature. Istraživačku prazninu treba dokazivati pregledom relevantnog polja, a ne samo prazninom u jednom generiranom odgovoru.

Četvrto ograničenje jest pridržavanje zadatka. Dugi postupak može završiti izvješćem koje krši dio kriterija: drugi vremenski raspon, druga populacija ili niz općenitih zaključaka bez pojedinačnih izvora. Usporedite rezultat s početnim planom. Ta je provjera jednostavna ako ste kriterije prethodno zapisali; mnogo je teža ako ih tek naknadno prilagođavate dobivenom tekstu.

Kako provjeriti i preraditi izvješće

Prvo pročitajte naslove i zaključak. Zatim izdvojite tri tvrdnje koje su najvažnije za vaše pitanje. Za svaku otvorite izvor i provedite trostruku provjeru iz prethodnog poglavlja. To je početna revizija, ne zamjena za provjeru svih tvrdnji koje ćete preuzeti u svoj rad. Broj izvora i izgled citata nisu potvrda da je sadržaj potkrijepljen.

Ne oslanjajte se na boju teksta, oznaku pouzdanosti ili gumb za automatsku provjeru kao na certifikat točnosti. Čak i kada takva pomoć postoji, istraživačko je pitanje šire: podupire li navedeni odlomak baš ovu tvrdnju, za ovu populaciju i ovu vrstu zaključka? U ovom izdanju zato zamjenjujemo stare upute o zelenim i narančastim oznakama izravnim otvaranjem izvora.

Napravite jednostavnu evidenciju nalaza: zadržati, provjeriti, suziti ili izostaviti. Primjerice, dobru definiciju mjere možete zadržati uz izvor; tvrdnju o „svim europskim kućanstvima” suziti na uzorak studije; broj bez izvora izostaviti. Ako se dva izvora razlikuju, nemojte ih automatski izjednačiti u kompromisnu tvrdnju. Razlika može proizlaziti iz pitanja, mjere, razdoblja ili istraživačkog dizajna.

Sačuvajte plan, datum pretrage, popis izvora i vlastite bilješke. Generirano izvješće služi kao radni materijal. Njegovu strukturu možete preraditi, ali svaka tvrdnja u završnom pregledu treba imati mjesto u vašem dokaznom zapisu. Kada pišete, uspoređujte radove po doprinosu pitanju umjesto da prepričavate jedan za drugim.

Povezivanje s nastavnim skupom

Za osnovni zadatak ne trebate cijelo istraživanje medija. Trebate razumjeti HICP i anketni saldo, ograničiti opisno pitanje i odrediti što ćete prikazati. Korisna početna sinteza odgovara na tri pitanja: što svaka mjera mjeri, koje su njezine granice i kakvu usporedbu vremenskih serija dopušta.

Nakon čitanja metodologije možete odlučiti prikazati dvije odvojene serije sa zajedničkom vremenskom osi, izračunati godišnje sažetke i opisati suvremenu korelaciju. Ne trebate odmah dodati panel model, sentiment medija ili predviđanje inflacije. Svako proširenje traži nove podatke i novi argument. Dobar pregled pomaže vidjeti te zahtjeve prije kodiranja.

Vježba: od plana do provjerene stranice

Sastavite plan za vlastito pitanje i napišite što bi vas navelo da ga promijenite. Ako imate pristup istraživačkom načinu rada, pokrenite ga; dok čekate, provjerite jedan već pronađeni izvor. Nije potrebno završiti cijeli postupak u unaprijed zadanih petnaest minuta. Za samostalno čitanje važnija je kvaliteta provjere od brzine odgovora.

Kada izvješće stigne, provjerite tri ključne tvrdnje, zabilježite jednu prazninu i napišite vlastiti sažetak na jednoj stranici. Razdvojite potvrđeno, vjerojatno i zasad nepoznato. Ako nemate pristup alatu, napravite isti plan i sažetak iz tri početna izvora radionice. Ishod je isti: organizirano znanje čiju potporu možete pokazati.

1.4 Od bilješki do nacrta rada s Claudeom

Imate izvore, ali još nemate argument

Ako ste pratili prethodna poglavlja, sada imate popis izvora, provjerene tvrdnje i bilješke o otvorenim pitanjima. To je više materijala nego na početku, ali pojavljuje se novi problem: imate fragmente, ne priču. Imate informacije, ali još ne znate redoslijed kojim ih treba objasniti čitatelju.

Upravo je to koristan zadatak za razgovornog asistenta. Claude ovdje ostaje primjer alata kojemu dajete vlastite materijale i od kojega tražite organizaciju, pitanja i kritičke komentare. Ista se vještina može vježbati u drugom dostupnom sustavu ili s kolegom. Vrijednost nije u tvrdnji da je jedan proizvod najbolji za hrvatski jezik, nego u jasnoći razgovora koji vodite o svom istraživanju.

Zamislite razgovor s mentorom. Ne dolazite samo s molbom „pomozi mi”, nego objašnjavate pitanje, raspoložive podatke i mjesto na kojem ste zapeli. Asistentu također treba dati te informacije. Razlika je u tome što odgovor modela morate provjeriti i kada zvuči kao siguran stručni savjet.

Pripremite materijale prije razgovora

Odvojite tri vrste sadržaja: provjerene bilješke, vlastite pretpostavke i otvorena pitanja. Uz izvor navedite naziv datoteke i mjesto relevantnog odlomka. Uz broj navedite jedinicu, razdoblje i skriptu ili tablicu iz koje potječe. Ako je rečenica samo radna ideja, označite je tako da model ne bi ugradio pretpostavku u nacrt kao već potvrđen nalaz.

Claude Projects omogućuje organiziranje materijala i projektnih uputa. Dokumentacija projektnog dohvaćanja opisuje korištenje relevantnih dijelova datoteka kada sadržaj nadilazi raspoloživi kontekst. To nije isto što i čitanje svih priloženih dokumenata u cijelosti pri svakom odgovoru. Za ključnu tvrdnju navedite točan dokument i zatražite mjesto na kojem se temelji odgovor.

Projektne upute mogu biti kratke: piši hrvatski, razlikuj podatak od pretpostavke, ne dodaj izvore koje nisi otvorio i označi nedostatak dokaza. Takve upute usmjeravaju rad; ne mijenjaju naučene težine modela i ne jamče da će svaki odgovor biti točan. Korisnije su provjerljive granice od dugog opisa zamišljene osobnosti stručnjaka.

Pet načela za koristan upit

1. Dajte kontekst i jasno zaduženje. Umjesto „pomozi mi s radom” napišite:

> Pripremam kratki studentski izvještaj o ostvarenoj inflaciji i saldu očekivanih promjena cijena u Hrvatskoj od 2015. do 2024. Imam 120 mjesečnih opažanja i tri provjerena izvora. Pomozi mi urediti plan opisne analize. Nemam medijske podatke ni istraživački dizajn za procjenu uzročnog učinka. Najprije navedi nejasnoće u mom planu.

Uputa „budi kritički recenzent” može pomoći objasniti vrstu komentara, ali ne pretvara model u recenzenta s provjerenim kompetencijama. Kontekst, materijali i kriteriji provjere čine glavninu korisne upute.

2. Odredite format i opseg. Ako želite nacrt, tražite nacrt, a ne cijeli rad. Ako želite usporedbu izvora, zatražite teme, slaganja, razlike i ograničenja. Primjer:

> Predloži pet odjeljaka: pitanje, podaci, postupak, rezultati i ograničenja. Za svaki napiši svrhu, dokaz koji je potreban i pitanje na koje još moram odgovoriti. Nemoj pisati nalaze prije nego što dobiješ izlaz analize.

3. Dajte primjer željenog rezultata. Jedan dobro napisan odlomak ili jedan dovršen dokazni zapis često je korisniji od mnoštva stilskih pridjeva. Primjer mora sadržavati istinite podatke ili jasno označena mjesta za unos. U suprotnom će se i pogreška iz primjera proširiti na ostatak.

4. Tražite kritiku, a ne potvrdu. Izvorni prompt koji je tražio obrazloženje već odabrane Newey-West korekcije previše je usmjeravao odgovor. Bolji upit pita je li metoda uopće potrebna, koje pretpostavke zahtijeva i što ne rješava. Jednako vrijedi za pitanje o istraživačkoj praznini: neka model razlikuje prazninu u vašim bilješkama od tvrdnje da nešto nitko još nije istražio.

5. Poboljšavajte pojedinačne dijelove. Nakon prvog nacrta izaberite jedan problem. „Pojasni zašto saldo nije postotna prognoza” preciznije je od „učini tekst akademskijim”. Sačuvajte inačice i odbacite prijedlog koji mijenja značenje. Više iteracija nije samo po sebi dokaz više kvalitete.

Demonstracija: četiri koraka do izvedivog plana

U prvom koraku prikupite bilješke. U našem primjeru one mogu glasiti: „Imam mjesečni HICP, godišnju stopu promjene; imam kvalitativni saldo očekivanja; podaci pokrivaju Hrvatsku 2015.–2024.; želim usporediti kretanja; nisam siguran/na kako opisati odnos.” Uključite definicije iz rječnika, a ne samo nazive stupaca.

U drugom koraku zatražite analizu praznina:

> Razdvoji što već mogu istražiti ovim podacima, što trebam dodatno provjeriti u metodologiji i što zahtijeva nove podatke. Za svaku preporuku objasni vezu s mojim pitanjem. Ne dodaj varijable koje nemam.

Koristan odgovor može upozoriti na različite jedinice i vremenski horizont ankete. Prijedlog da analizirate medijski sentiment zahtijeva novi korpus, pravilo mjerenja i provjeru kvalitete. Nije mala dopuna postojećem planu. Razlikovanje tih razina štiti vas od nacrta koji obećava znatno više nego što se može napraviti.

U trećem koraku odredite redoslijed argumenta. Najprije objasnite pitanje i mjere, zatim provjeru podataka, vizualni prikaz i sažetke, a na kraju interpretaciju i ograničenja. Svaki odjeljak treba imati posao koji obavlja. Naslov „Metodologija” bez informacije što je izračunato nije dovoljan plan.

U četvrtom koraku popravite najslabije mjesto. Ako nacrt zaključuje da mediji oblikuju očekivanja, vratite ga na ono što podaci sadrže. Ako predviđa regresiju zato što rad „mora biti ozbiljan”, pitajte na koje pitanje ta regresija odgovara. Opisna analiza može biti dovršen i vrijedan studentski zadatak kada su mjere i ograničenja dobro objašnjeni.

Hipoteze, teorija i rezultat ne nastaju istim putem

Model može predložiti hipoteze. Istraživač provjerava jesu li jasne, zanimljive, povezane s teorijom i mjerljive dostupnim podacima. Nije potrebno tvrditi da AI ne može predložiti originalnu ideju da bismo razumjeli zašto konačna odgovornost ostaje na autoru.

Hipoteza nastala nakon gledanja grafa dio je eksploracije. Nemojte je naknadno prikazati kao unaprijed postavljenu potvrđujuću hipotezu. Ako želite provjeravati prognozu, treba unaprijed razjasniti ciljnu varijablu, horizont i razdoblje evaluacije. Ako želite uzročni zaključak, potrebno je obrazložiti identifikaciju. Nacrt ne smije preskočiti te razlike.

Za kritiku izvora možete zatražiti procjenu jasnoće pitanja, podataka, metode i granica zaključka. Ako modelu dajete samo sažetak, neka i komentar bude ograničen na sažetak. Zaključivanje o detaljima specifikacije koje ni vi ni model niste vidjeli nije kritičko čitanje.

Nacrt koji možete braniti

Završite prvi dan s pitanjem, trima provjerenim izvorima i planom na jednoj stranici. Uz plan dodajte popis otvorenih pitanja i naziv prve skripte koju ćete pokrenuti. Za svaku planiranu tablicu ili sliku napišite koju rečenicu treba pomoći objasniti. Time stvarate vezu između čitanja, analize i pisanja.

Kao samostalnu vježbu zamijenite nacrt s kolegom. Neka označi jednu tvrdnju bez dokaza, jedan nejasan pojam i jedan korak koji se ne može izvesti raspoloživim podacima. AI može predložiti istu vrstu pitanja, ali vi trebate znati odgovoriti bez ponovnog prepuštanja razgovora modelu. To je najbolja priprema za drugi dan, kada će svaki izbor postati dio konkretnog postupka.

Drugi dan: kodiranje i pisanje

2.1 Agentsko kodiranje i provjerljiva analiza

Od prijedloga koda do izvršavanja zadatka

Prvoga dana istraživačko ste pitanje povezali s izvorima i podacima. Drugoga dana taj plan treba pretvoriti u postupak. Programska pomoć može biti dopunjavanje retka, razgovor o skripti ili agent koji čita datoteke, predlaže izmjene i pokreće naredbe. Te mogućnosti nisu strogo odvojene generacije tehnologije; često postoje unutar iste aplikacije.

Claude Code ostaje primjer agentskog pristupa iz izvornog materijala. Važna promjena u načinu rada jest da alat može iz prijedloga prijeći na radnju. Ako mu okruženje i dopuštenja to omogućuju, može urediti nekoliko datoteka i izvršiti analizu. Time se smanjuje ručno prepisivanje, ali se povećava važnost jasno zadanog opsega i provjere promjena.

Zamislite istraživačkog suradnika kojemu predajete radnu mapu. Treba mu reći što se smije mijenjati, koje datoteke predstavljaju izvorne podatke i kako izgleda prihvatljiv rezultat. „Analiziraj ovo” ostavlja previše prostora za proizvoljan izbor uzorka i metode. „Provjeri mjesece i jedinice, zatim reproduciraj postojeći graf” određuje provjerljiv korak.

Kontekst, upute i dopuštenja

Dokumentacija Claude Code memorije razlikuje projektne upute i automatski spremljene bilješke. Takve datoteke pomažu kontinuitetu, ali nisu potpuna arhiva svega što se dogodilo. Istraživački dnevnik, spremljene skripte i povijest promjena i dalje su potrebni. Nemojte pretpostaviti da se važna odluka pamti samo zato što ste je jednom napisali u razgovoru.

Povezivanje s dodatnim alatima, primjerice putem MCP-a, može proširiti što agent može čitati ili izvršiti. To ne znači da automatski ima pristup svakoj bazi ili pravo na sve radnje. Prije rada provjerite dostupne funkcije i dopuštenja. Tekst s weba ili iz učitane datoteke istraživački je materijal; upute skrivene u njemu ne trebaju određivati vaš radni postupak.

Rad u zasebnoj grani omogućuje pregled izmjena prije njihova prihvaćanja. Sama grana nije sigurnosna izolacija računala. Podagenti, kada su dostupni, također ne znače da je svaka izmjena automatski odvojena i provjerena. Za studentski zadatak često je dovoljno zadavati male uzastopne korake i pregledati kod nakon svakog od njih.

Primjer početnog zaduženja:

> Radi unutar ovog nastavnog projekta. Najprije pročitaj rječnik podataka i postojeće skripte. Izvorne datoteke u data/raw ostavi nepromijenjene. Provjeri broj mjeseci, datumski raspon, duplikate, nedostajuće vrijednosti i jedinice. Prikaži plan i nalaze provjere. Nemoj brisati opažanja, interpolirati podatke ni mijenjati istraživačko pitanje bez obrazloženja.

Korak 1: upoznajte ulazne podatke

Jedan redak naše tablice predstavlja mjesec u Hrvatskoj. Ključ `month` povezuje mjesece, `hicp_yoy_pct` predstavlja godišnju stopu promjene HICP-a, a `expectations_balance` kvalitativni anketni saldo. Naziv „monthly" u opisu frekvencije ne znači da je stopa promjene izračunata prema prethodnom mjesecu. Podatak se objavljuje mjesečno, a stopa uspoređuje cijene s istim mjesecom prethodne godine.

Prije analize potvrdite 120 uzastopnih mjeseci, od siječnja 2015. do prosinca 2024. Provjerite ima li dvostrukih zapisa, praznina i neočekivanih vrijednosti. Usporedite nekoliko vrijednosti s izvornim JSON datotekama. U manifestu su parametri dohvata i kontrolni sažeci datoteka. Zamrznuta kopija omogućuje da kasnija revizija službenih podataka ne promijeni neprimjetno rezultat ove nastavne verzije.

Agent može napisati te provjere, ali vi određujete što očekujete i zašto. Broj redaka sam po sebi nije dovoljan: 120 redaka može sadržavati jedan ponovljen i jedan izostavljen mjesec. Isto vrijedi za graf koji izgleda glatko i uvjerljivo, a počiva na pogrešno spojenim datumima.

Korak 2: priprema bez prikrivenih odluka

„Očisti podatke" preširok je zadatak. Nedostajuća vrijednost nije nula. Ekstremna inflacija tijekom gospodarskog šoka nije automatski pogreška. Prije brisanja, zamjene ili transformacije treba razumjeti izvor i napisati pravilo. Čuvajte izvorne podatke te promjene provodite u skripti.

Jedna zemlja praćena kroz vrijeme čini vremensku seriju, a ne panel više zemalja. Panel traži više jedinica koje se promatraju kroz vrijeme. Dodavanje još jedne mjere istoj zemlji ne pretvara tablicu u panel. Ta razlika određuje koje je modele uopće smisleno razmatrati.

Ne primjenjujte logaritam na saldo koji može biti negativan ili na stopu koja može biti nula ili negativna bez jasnog teorijskog i matematičkog razloga. Ni nakon logaritmiranja neke varijable svaki koeficijent ne postaje elastičnost; interpretacija ovisi o specifikaciji. Jednako tako, spajanje dnevnih i mjesečnih podataka zahtijeva smisleno pravilo agregacije, a ne automatsku interpolaciju koju je alat ponudio.

Korak 3: slika prije modela

Dvije serije imaju različite jedinice. U radionici ih prikazujemo u odvojenim panelima sa zajedničkom vremenskom osi. Čitatelj vidi kada se promjene događaju, ali ih ne zamjenjuje za brojčano usporedive veličine. Dvije neovisno skalirane y-osi mogu proizvesti privid preklapanja linija ovisno o odabranom rasponu. Tehnička sposobnost izrade takvog grafa nije razlog da ga koristimo.

Pogledajte razdoblja ubrzanja, usporavanja i promjena raspona. Opisujte ono što slika pokazuje, a moguća objašnjenja navedite kao pitanja za daljnje istraživanje. Ne proglašavajte strukturni lom samo na temelju vizualnog dojma, niti smjer uzročnosti na temelju toga koja linija ranije raste. Za to trebaju dodatni postupci i pretpostavke.

Pearsonova korelacija sažima linearnu povezanost parova opažanja. U zamrznutom uzorku cijelog razdoblja iznosi približno 0,6985; u dijelu 2015.–2019. približno 0,8279, a u dijelu 2020.–2024. približno 0,5342. Te su vrijednosti reproducirane u `results/correlations.csv`. Razlika među podrazdobljima pokazuje da sažetak ovisi o promatranom razdoblju. Nije test razlike korelacija niti dokaz promjene uzročnog mehanizma.

Korak 4: što regresija i HAC mogu pokazati

Osnovni zadatak završava opisnim rezultatima. Za napredne čitatelje zadržavamo izvorno objašnjenje OLS-a, ali uz važne korekcije. Jednostavan model s konstantom može se napisati kao

$y_t = \alpha + \beta x_t + u_t$.

U nastavnom dodatku y_t je ostvarena inflacija, a x_t saldo očekivanja u istom mjesecu. Koeficijent opisuje linearnu povezanost u tom modelu. Anketno pitanje gleda unaprijed, ali njegovo uključivanje u regresiju s ostvarenom inflacijom istog mjeseca ne čini model testom prognozne točnosti. Za prognozu treba uskladiti cilj, horizont i dostupnost informacija u trenutku predviđanja.

Konvencionalne standardne pogreške OLS-a počivaju na pretpostavkama o greškama. Kod heteroskedastičnosti ili serijske korelacije mogu biti neprimjerene; nije zajamčeno da su uvijek preniske. HAC procjena kovarijacijske matrice, primjerice Newey-West, mijenja procjenu nesigurnosti uz odgovarajuće uvjete. Ne mijenja same OLS koeficijente i ne ispravlja endogenost, izostavljene varijable, loše mjerenje ili lažnu regresiju povezanu s nestacionarnošću.

U `sandwich::NeweyWest` važni su odabir odmaka, prethodno izbjeljivanje i korekcija za veličinu uzorka. Naš dodatak navodi postavke izričito: `lag = 12`, `prewhite = FALSE`, `adjust = TRUE`. Dvanaest je nastavna specifikacija za mjesečne podatke, a ne univerzalno optimalan odabir. Procjena i interpretacija traže pregled dinamike i osjetljivosti na razumne postavke.

P-vrijednost se odnosi na kompatibilnost rezultata s nul-hipotezom i pretpostavkama modela: pod tim uvjetima izražava vjerojatnost statistike barem toliko ekstremne koliko je opažena. Nije vjerojatnost da je nul-hipoteza istinita, ni veličina učinka, ni vjerojatnost da je nalaz nastao „slučajno”. ASA-ina izjava objašnjava zašto znanstveni zaključak ne treba svesti na prelazak praga. Prikladnost dizajna prethodi tumačenju p-vrijednosti.

Korak 5: osjetljivost i granice proširenja

Izvorni tekst uvodio je multiverzum modela i specifikacijsku krivulju. Zadržavamo ideju da se rezultat ne bi trebao oslanjati na jednu proizvoljnu odluku. Ipak, skup specifikacija mora sadržavati obrazložive alternative, a ne sve kombinacije koje računalo može generirati. Stotine loše postavljenih modela ne proizvode valjan zaključak.

Prije pregleda rezultata zapišite koje ćete odluke usporediti i zašto. Primjerice, možete opisno usporediti ista razdoblja kao u referentnim rezultatima, razmotriti odmake koje opravdava pitanje ili alternativno mjerenje kada je dostupno. Prikažite sve planirane

rezultate i objasnite izostavljene specifikacije. Ne birajte samo onu s povoljnim predznakom ili najmanjom p-vrijednošću.

Za medijski nastavak trebali biste pribaviti korpus s podrijetlom i uvjetima uporabe, definirati uključivanje članaka, ukloniti duplikate po opisanom pravilu te provjeriti mjerenje pažnje ili tona. Ručno označen uzorak može pomoći evaluaciji klasifikacije. To je zaseban projekt; u izvornim materijalima spominjani broj članaka ovdje ne predstavljamo kao potvrđen skup podataka.

Kako provjeriti rad agenta

Pregledajte razliku izmjena, pročitajte ključne retke i pokrenite postupak od početka. Usporedite barem jedan rezultat neovisnim izračunom. Ne zadovoljavajte se rečenicom agenta da su „svi testovi prošli”: pogledajte što je provjereno. Provjera sintakse ne potvrđuje ekonomsku interpretaciju.

Kao vježbu napišite precizno zaduženje za izradu godišnjeg sažetka. Zahtijevajte broj mjeseci u svakoj godini, definiciju prosjeka i izvoz rezultata. Objasnite zašto prosjek dvanaest mjesečnih godišnjih stopa promjene nije isto što i promjena godišnjeg prosjeka indeksa. Prihvatite kod tek kada razumijete tu razliku i možete pratiti broj od ulaza do tablice.

2.2 Rad u editoru: Copilot, RStudio i Positron

Mali koraci olakšavaju učenje

Agentsko izvršavanje korisno je kada znate koji postupak želite ostvariti. Tijekom učenja često je bolje stati nakon malog koraka: pročitati tablicu, ispitati jednu varijablu i objasniti jednu transformaciju. Razvojno okruženje, odnosno IDE, okuplja editor, konzolu i prikaz rezultata. AI asistent u njemu može dopuniti kod ili objasniti pogrešku dok vi pratite što se izvršava.

Izvorna analogija pomoćnika koji dodaje alat dok vi radite ostaje korisna. Prijedlog treba pročitati prije prihvaćanja, a rezultat nakon izvršavanja. Pritiskanje tipke za prihvaćanje nije provjera. Ako ne znate što funkcija radi, tražite objašnjenje na malom primjeru i usporedite ga s dokumentacijom.

Ispravljena usporedba okruženja

RStudio i Positron mogu poslužiti za ovu radionicu. RStudio ima dokumentiranu integraciju Copilota, pa stara tvrdnja da ga ne podržava nije točna. Nema potrebe objašnjavati izbor editora netočnom pričom da su cijelo sučelje RStudija i svi njegovi procesi jedan R proces. Odvojite pitanje mogućnosti alata od pitanja istraživačke metode.

Positron je okruženje za rad s R-om i Pythonom. Njegova dokumentacija proširenja objašnjava način instalacije i ograničenja kompatibilnosti; ne treba pretpostaviti da svako proširenje za VS Code radi na isti način. Za ovu radionicu važni su otvaranje projektne mape, odabir R-a, čitanje skripte, izvršavanje i pregled izlaza. AI dodatak ostaje izborna pomoć.

Konkretna novost provjerena za ovo izdanje: prema Positovoj dokumentaciji, Posit Assistant od verzije Positrona 2026.07 zamjenjuje prethodni Positron Assistant i Databot. Stare upute o sučelju mogu se odnositi na stariji proizvod. Provjerite instaliranu verziju i odgovarajuće upute. Ne pretpostavljajte da se dostupni modeli, naredbe i dozvole podudaraju u svakoj instalaciji.

Izbor se može svesti na praktična pitanja: u kojem okruženju znate otvoriti projekt, kako vidite izvršeni kod, možete li ponovno pokrenuti sve od početka i gdje završavaju izlazne datoteke? Promjena editora sama po sebi ne povećava valjanost analize. Dobra radna navika prenosiva je između okruženja.

Tri vrste pomoći koje treba razlikovati

Linijsko dopunjavanje predlaže nastavak uz kursor. Korisno je za ponavljajuću sintaksu i male funkcije. Provjerite nazive stupaca, argumente i smjer filtra. Prijedlog koji je sintaktički točan može koristiti varijablu iz nekog drugog projekta ili pretpostaviti pogrešnu jedinicu.

Razgovor o kodu služi objašnjenjima i usmjerenim pitanjima. Umjesto „popravi sve” navedite poruku o pogrešci, relevantan dio skripte i očekivani ishod. Tražite objašnjenje

uzroka, a zatim najmanju promjenu koja ga rješava. Nemojte izostaviti upozorenje samo zato što se graf ipak prikazao.

Uređivanje i agentsko izvršavanje mogu zahvatiti više datoteka. Njihova dostupnost ovisi o proizvodu i integraciji. Pregled izmjena, dopuštenja i izvršenih naredbi važniji je od opće etikete „IDE" ili „agent". Terminalski alat može omogućiti detaljnu provjeru, a pomoćnik u editoru može izvoditi opsežne radnje.

Demonstracija na istim podacima

Otvorite korijen preuzetog projekta. Sljedeći mali primjer koristi osnovni R i iste podatke kao službene skripte. Svrha mu je pokazati što čitate i provjeravate; završni postupak radionice ostaje zapisan u datotekama u mapi `code`.

```
d <- read.csv("data/processed/croatia_inflation.csv")
stopifnot(nrow(d) == 120L, !anyDuplicated(d$month))
str(d)
head(d)
```

Pitajte asistenta što provjerava `stopifnot`, a što još ne provjerava. Primjer potvrđuje broj redaka i jedinstvenost mjeseca, ali ne i potpunost kalendara ili definiciju varijabli. Usporedite ga s opsežnijom provjerom u projektu. Dobro objašnjenje navodi i ograničenje vlastitog koda.

Zatim izračunajte jednostavan sažetak:

```
summary(d[c("hicp_yoy_pct", "expectations_balance")])
colSums(is.na(d))
```

U ovoj tablici prazna polja `hicp_flag` i `expectations_flag` znače da nema dodatne oznake statusa podatka; nisu isto što i nedostajuća vrijednost inflacije ili salda. Zato popis iz `colSums` čitajte zajedno s rječnikom podataka. Automatsko uklanjanje svakog retka koji ima bilo koje prazno polje uklonilo bi i valjana opažanja.

Zahtjev „napravi profesionalnu tablicu" prerano usmjerava pažnju na izgled. Prvo provjerite mjere, broj opažanja i nedostajuće vrijednosti. Naknadno možete urediti naslove i broj decimala. Uredna tablica ne uklanja problem ako su u istoj koloni pomiješane stope i indeksi.

Za godišnji prosjek napišite pravilo prije koda: grupiramo prema godini, očekujemo dvanaest mjeseci i prosječno računamo mjesečne godišnje stope. To nije nova mjera godišnje promjene prosječnog indeksa. Asistent neka objasni svaki argument i provjeri `n_months` prije sažimanja.

Za vizualizaciju zatražite dva panela sa zajedničkom osi vremena, jasnim jedinicama i izvorom. Ispravite oznaku ako piše „očekivana inflacija (%)". U našem slučaju odgovarajuća je oznaka „saldo očekivanih promjena cijena". Navedite i da HICP predstavlja godišnju stopu promjene, kako čitatelj ne bi pretpostavio mjesečnu promjenu.

Dijagnosticiranje umjesto nasumičnog popravljanja

Kada kod ne radi, prvo pročitajte poruku i utvrdite u kojem koraku nastaje problem. Nedostajuća datoteka često je problem radnog direktorija. Nepostojeći stupac može značiti pogrešno ime ili drukčiji način učitavanja. Ne popravljajte taj simptom preimenovanjem svega što model predloži bez usporedbe s rječnikom podataka.

Koristan upit glasi:

> Ova naredba javlja sljedeću pogrešku: [poruka]. Radim iz korijena projekta, a ulazna datoteka ima ove nazive stupaca: [nazivi]. Objasni vjerojatan uzrok i predloži najmanju izmjenu. Nemoj mijenjati definicije varijabli ni izostavljati opažanja da bi kod prošao.

Provjerite rješenje u čistoj sesiji. Objekt koji je ostao od ranijeg pokretanja može prikriti nedostajući korak. Spremite skriptu, ponovno pokrenite R i izvodite je od početka. Taj postupak vrijedi i u RStudiju i u Positronu; nije svojstvo samo jednog editora.

Napredni koraci imaju preduvjete

Proširenje s Hrvatske na više zemalja traži usklađene definicije, obuhvat i datume. Tek tada ima smisla razmatrati panel pristup. Izbor fiksnih ili slučajnih efekata ne treba svesti na automatsko pravilo temeljeno na jednoj p-vrijednosti. Način uzorkovanja, pretpostavke o neopaženim razlikama i struktura zavisnosti određuju koje su procjene i standardne pogreške prikladne.

Takva analiza nije završni korak petnaestominutne početničke vježbe. Zadržavamo je kao mogući nastavak, uz mentorovu pomoć i prikladne podatke. U osnovnoj radionici važnije je razumjeti malu izmjenu postojećeg koda nego prihvatiti veliki model koji ne možete objasniti.

Vježba: promjena koju možete objasniti

U `code/starter.R` odaberite jedan mali zadatak. Primjerice, poboljšajte oznaku grafa ili dodajte broj opažanja uz sažetak. Zatražite prijedlog, pročitajte ga i napišite jednu rečenicu o tome što se mijenja. Pokrenite skriptu i usporedite rezultat prije i poslije. Ako se zbog promjene oznake promijenio broj opažanja ili izračunata vrijednost, istražite zašto.

Za samostalni nastavak zapišite jedan prihvaćen i jedan odbijen AI prijedlog. Obrazložite oba izbora. Takva bilješka pokazuje učenje bolje od broja generiranih redaka. Ishod rada u editoru je skripta čiji postupak razumijete i koju druga osoba može pokrenuti.

2.3 Bilježnice, eksploracija i reproducibilnost

Istraživački dnevnik koji izvršava kod

Zamislite bilježnicu u kojoj zapisujete pitanje, odmah ispod njega izvodite izračun, a zatim dodajete graf i komentar. Takav dokument može biti i istraživački dnevnik i radno okruženje. Računalne bilježnice spajaju tekst, kod i rezultate; AI pomoć može dodati razgovorno sučelje za pisanje i objašnjavanje koda.

Ipak, ne predstavljaju sva razgovorna sučelja istu vrstu dokumenta. Chat koji prikazuje graf, interaktivni prikaz izrađen u razgovoru i Jupyter bilježnica nemaju nužno isti način spremanja koda i izvođenja. Prije analize provjerite možete li vidjeti izvršeni kod, preuzeti podatke i rezultat te ponovno pokrenuti postupak iz prazne sesije.

Googleova dokumentacija Colaba opisuje razgovornu pomoć, izmjene koda i agentske postupke unutar bilježnice. Pristup ovisi o računu i dostupnosti funkcije. Za učenje je važnije razumjeti što je izvršeno nego pamtiti koji se model nalazi u pozadini pojedinog proizvoda.

Bilježnica nije nužno samo privremena skica. Može biti kvalitetan završni istraživački dokument ako uključuje sav potreban kod, opis ulaza i okruženja te se može izvršiti pravilnim redom. Suprotno tome, ni skripta u repozitoriju nije automatski reproducibilna. Presudni su sadržaj i provjeren postupak, a ne naziv formata.

Pet pitanja za eksploraciju

U izvornom materijalu demonstracija je naglo prelazila na američke podatke o komunikaciji središnje banke. Ovdje nastavljamo s istih 120 hrvatskih mjeseci kako biste mogli usporediti različite načine rada bez istodobnog učenja novog skupa podataka.

Prvo pitanje: što je učitano? Prikažite broj opažanja, nazive i tipove stupaca, nekoliko redaka te vremenski raspon. Usporedite odgovor modela sa stvarnom tablicom. Ako model saldo nazove „očekivanom inflacijom u postocima”, ispravite definiciju prije bilo kakvog grafa.

Drugo pitanje: kako se mjere kreću kroz vrijeme? Zatražite dva panela sa zajedničkom vremenskom osi. Jasno navedite jedinice i razdoblje. Provjerite da kronološki redoslijed nije zamijenjen abecednim ili redoslijedom nastanka objekata. U ovom skupu tekstualni format YYYY-MM omogućuje kronološko sortiranje, ali to nije svojstvo svakog formata datuma.

Treće pitanje: kakav je raspon i raspodjela? Sažetak i histogram otkrivaju različite stvari. Histogram prikazuje raspodjelu, ali skriva vremenski slijed; vremenski graf čuva slijed, ali slabije pokazuje koliko je često pojedina vrijednost zastupljena. Koristite ih za različita pitanja. Minima i maksima ne proglašavajte pogreškama bez provjere izvora.

Četvrto pitanje: koliko je sažetak osjetljiv na razdoblje? Izračunajte korelaciju za cijeli uzorak i dva unaprijed navedena podrazdoblja. Objasnite da se uspoređuju isti mjeseci dviju serija. Ako želite ispitati vremenski odmak, napišite koju varijablu pomičete, u kojem

smjeru i zašto. Nemojte iskušavati odmake dok ne dobijete najveći koeficijent i prikazati ga kao jedini rezultat.

Peto pitanje: što je sljedeće istraživačko pitanje? Eksploracija može otvoriti hipotezu o razlikama između razdoblja, ali ne daje automatski njezinu potvrdu. Zapišite kada je ideja nastala i kakvi su dodatni podaci ili dizajn potrebni. AI prijedlog da dodate medijski ton nije rezultat postojeće tablice, nego mogući novi projekt.

Skriveno stanje: zašto dokument radi samo vama

Bilježnica može sadržavati ćeliju koja koristi objekt stvoren ranije, ali čija je izrada poslije izbrisana. Možete izvršiti ćelije redoslijedom 3, 1, 4, promijeniti podatke i zaboraviti ponovno pokrenuti graf. Na ekranu tada vidite uredan niz rezultata koji ne odgovara redoslijedu koda u spremljenom dokumentu. To je problem skrivenog stanja.

AI ga može dodatno zamagliti ako kaže da je „ponovno izračunao sve", a izmijeni samo jednu ćeliju. Rješenje je konkretno: spremite dokument, ponovno pokrenite jezgru i izvršite sve ćelije od početka. Provjerite rezultate i spremite ih nakon uspješnog izvođenja. Ako postupak ne radi, pronađite nedostajući korak umjesto da se oslonite na staru sliku.

Isti problem postoji u interaktivnoj R konzoli. Objekt iz jučerašnje sesije može omogućiti današnjoj nepotpunoj skripti da radi. Zato radionica traži pokretanje spremljenog postupka od početka. Uspješno ponovno izvođenje s poznatim ulazom uvjerljivije je od dugog razgovora o tome što je navodno napravljeno.

Reproducirati analizu nije isto što i ponoviti prompt

Ako sutra pošaljete isti upit modelu, može nastati drukčiji kod. Model, postavke, dostupni alati ili izvori također se mogu promijeniti. Za reprodukciju našeg numeričkog rezultata zato čuvamo prihvaćeni kod i ulazne podatke, a ne očekujemo da model ponovno napiše istu analizu. Zapis upita objašnjava nastanak rada, ali nije zamjena za skriptu.

Za slučajne postupke treba navesti sjeme generatora i relevantne postavke. Za vanjske izvore treba sačuvati datum dohvata i, kada je dopušteno, korištenu kopiju. Za softverske ovisnosti treba opisati verzije i način obnove okruženja. renv pomaže upravljanju R paketima, ali sama zaključana lista paketa ne jamči prisutnost svih sistemskih biblioteka, podataka ili vanjskih usluga.

Ne trebate automatski uvoditi Docker i složenu infrastrukturu u svaki studentski zadatak. U ovom osnovnom primjeru dovoljne su javne spremljene datoteke i osnovni R. Složeniji projekti mogu tražiti izolirano okruženje i automatizirane provjere. Razina infrastrukture treba odgovarati stvarnim ovisnostima i riziku gubitka postupka.

Što treba izvesti iz razgovornog okruženja

Preuzmite skriptu ili bilježnicu, potrebne ulazne podatke ako to dopuštaju uvjeti uporabe, tablicu rezultata i graf. Dodajte opis koraka, verzije važnih paketa i bilješku o AI pomoći. Nemojte kao jedini dokaz predati snimku ekrana razgovora. Ona ne omogućuje provjeru brojeva ni promjenu pretpostavki.

Spremanje svih razgovora bez razlike također nije cilj. Mogu sadržavati osobne podatke ili nepotreban sadržaj. Sačuvajte relevantne odluke i potreban dokazni trag, uz pravila kolegija i zaštitu podataka. Primjer korisne bilješke: „Model je predložio interpolaciju; odbijena je jer zamrznuti skup nema praznina i takva transformacija nije dio plana."

Usporedite tri načina rada

Agent je praktičan za dobro ograničen zadatak nad više datoteka. Editor je praktičan kada želite pratiti i učiti male promjene. Bilježnica je praktična kada pitanja, kod i komentari trebaju stajati zajedno. Sve tri mogućnosti mogu biti transparentne ili nepregledne, ovisno o načinu uporabe. Ni jedna nema zajamčenu razinu kontrole ili reproducibilnosti.

Umjesto rangiranja proizvoda, usporedite isti mali zadatak u dvama okruženjima: koliko vam treba vremena do provjerenog rezultata, možete li objasniti svaku transformaciju, gdje se sprema kod i može li ga druga osoba pokrenuti? Ako ste brže dobili graf, a ne možete doći do koda, dobitak može nestati pri pisanju završnog rada.

Vježba: ponovno izvođenje bez razgovora

Napravite kratak eksplorativni dokument s pet pitanja iz ovog poglavlja. Spremite prihvaćeni kod, ponovno pokrenite okruženje i izvedite ga od početka. Usporedite broj mjeseci i korelaciju s referentnim datotekama. Zatim dajte kolegi postupak bez svoje otvorene sesije i usmenih dopuna. Zabilježite što mu je nedostajalo.

Vježba završava kratkim odgovorom na dva pitanja: što se može ponoviti iz spremljenih datoteka i što još ovisi o vama ili vanjskoj usluzi? Time spremate analizu za pisanje, gdje čitatelju treba pokazati i nalaz i način na koji ste do njega došli.

2.4 Pisanje i uređivanje akademskog teksta

Pisanje je dio istraživanja

Zamislite da ste prikupili podatke, provjerili skriptu i izradili graf. Sjednete pisati i shvatite da ne znate objasniti što ste otkrili. Odlomak zvuči kao dnevnik naredbi, zaključak obećava više nego što analiza daje, a čitatelj ne vidi vezu između pitanja i rezultata. Upravo zato pisanje nije samo posljednji korak. Ono vas prisiljava razlikovati što znate, što pretpostavljate i što još ne možete tvrditi.

AI može pomoći kao čitatelj nacrta: označiti nejasan pojam, predložiti redoslijed i upozoriti na rečenicu bez potpore. To je korist koju zadržavamo iz izvornog materijala. Ne trebamo je opravdavati nepotvrđenim postotkom uštede vremena ili tvrdnjom da svaki alat jednako dobro uređuje svaki jezik. Mjerite poboljšanje na vlastitom tekstu i uključite vrijeme provjere.

Korinekov pregled primjena u ekonomskim istraživanjima razlikuje ideaciju i povratne informacije, pisanje, pozadinsko istraživanje, analizu podataka, programiranje i matematičke derivacije. To je koristan popis zadataka za razmišljanje o podjeli rada. Nije dokaz trajne rang-liste ljudskih i strojnih sposobnosti, niti opće dopuštenje da bilo koji zadatak prepustite modelu bez provjere.

Opseg pomoći i pravila zadatka

Pravopisna korekcija, komentar strukture, prerada odlomka i pisanje novog teksta različito zadiru u autorov rad. Prihvatljivost određuju pravila kolegija, ustanove i namjene teksta. U ovoj radionici polazimo od vašeg pitanja, provjerenih izvora i vlastite interpretacije, a AI može predložiti komentare ili izmjene koje pregledavate.

Ni gramatička pomoć nije unaprijed dopuštena u svakom ispitu. Ni izjava „koristio/la sam AI” ne čini dopuštenim ono što je pravilima zabranjeno. Kada se pomoć smije koristiti, opišite konkretan zadatak i opseg. Autor odgovara za završne tvrdnje, citate i prikaz analize, bez obzira na to tko je predložio pojedinu formulaciju.

Parafraza treba pokazati razumijevanje izvora i zadržati atribuciju. Zamjena riječi sinonimima ne uklanja potrebu za citiranjem. Ako niste pročitali rad, nemojte njegov AI sažetak prikazati kao vlastito kritičko čitanje. Najprije utvrdite što rad tvrdi, zatim vlastitim riječima objasnite njegovu relevantnost.

Šest obrazaca koje možete prilagoditi

1. Jasnoća i stil. Dajte vlastiti odlomak i zatražite uklanjanje nepotrebnih riječi, objašnjenje nejasnih izraza i popis promjena. Izričito zadržite brojke, jedinice i razinu sigurnosti. „HNB je često u medijima” ne smije postati „empirijski podaci pokazuju pozitivnu korelaciju” ako takvu analizu niste proveli.

> Uredi jasnoću ovog odlomka. Ne dodaj činjenice, izvore ni rezultate. Sačuvaj jedinice i razliku između povezanosti i uzročnosti. Najprije navedi probleme, zatim predloži izmjene i objasni svaku bitnu promjenu.

2. Kritika argumenta. Tražite logičke praznine, skrivene pretpostavke i moguće alternativno objašnjenje. Ako odlomak povezuje očekivanja i inflaciju, model može upozoriti na zajedničke šokove ili obrnuti smjer povezanosti. Vi provjeravate jesu li prigovori relevantni za konkretan dizajn. Ne trebate prihvatiti svaki prigovor samo zato što je strogo napisan.

3. Prijelaz između odlomaka. Dajte dva susjedna odlomka i zatražite rečenicu koja objašnjava njihovu vezu. Dobar prijelaz čitatelju govori zašto nakon definicije mjere slijedi određeni izračun. Ako ta veza nije opravdana, možda treba promijeniti redoslijed ili ukloniti odlomak, a ne samo dodati veznu frazu.

4. Parafraza i atribucija. Priložite provjereni odlomak i bibliografske podatke. Zatražite prijedlog parafraze koji čuva granice nalaza te usporedite ga s izvornikom. Stil citiranja prilagodite uputama rada; model ne smije dopuniti nedostajuću godinu, naslov ili DOI nagađanjem.

5. Usklađenost uvoda i zaključka. Usporedite pitanje, obećani postupak i zaključnu tvrdnju. Ako uvod najavljuje uzročni učinak medija, a provedena je samo opisna usporedba inflacije i salda, problem se rješava promjenom pitanja i zaključka ili novim istraživanjem. Dodavanje riječi „možda” ne ispravlja neusklađen dizajn.

6. Radni predložak. Kada pravila dopuštaju, model može pomoći organizirati vaše točke u nacrt. Nepoznate podatke označite, primjerice `[unesi rezultat iz provjerene tablice]`. Predložak nije gotov tekst i takve oznake moraju nestati tek nakon stvarne provjere. Za završnu predaju svaku rečenicu trebate razumjeti i moći povezati s dokazom.

Obrnuti razgovor također je koristan: zatražite da vam model postavlja pitanja jedno po jedno prije predlaganja metodološkog odlomka. Primjerice, koje su jedinice, koji je uzorak i kako ste postupili s prazninama? To može otkriti odluku koju niste zapisali. Ne jamči da će model pitati sve potrebno, pa vlastiti kontrolni popis i dalje ima smisla.

Četiri prolaza kroz tekst

Prvi prolaz: evaluacija bez prepisivanja. Pročitajte odlomak s obzirom na pitanje, dokaz, jasnoću i granice zaključka. Zatražite konkretna mjesta koja treba popraviti. Ocjena „7 od 10” bez obrazloženja malo pomaže; korisniji je komentar „iz ove rečenice nije jasno da je očekivanje mjereno kvalitativnim saldom”.

Drugi prolaz: struktura. Posložite problem, mjere, postupak, nalaz i ograničenje. Definirajte pojam prije nego što ga tumačite. Tablicu ili graf uvedite rečenicom koja objašnjava što čitatelj treba gledati, a nakon prikaza objasnite relevantan nalaz. Nemojte opisivati sve brojeve redom ako ne služe pitanju.

Treći prolaz: usklađivanje snage tvrdnji. Zamijenite „dokazuje” s formulacijom koja točno odgovara dizajnu, a ne s neodređenom ogradom. „U uzorku postoji pozitivna linearna povezanost” preciznije je od „rezultati sugeriraju statistički značajan utjecaj” kada niste proveli odgovarajući test ni identificirali uzročni učinak.

Četvrti prolaz: jezik i dosljednost. Provjerite nazive mjera, decimalne oznake, datume, padeže i kratice. Isti konstrukt ne treba naizmjenično nazivati percepcijom, očekivanjem i

pouzdanjem ako to nisu iste varijable. Nakon jezične izmjene ponovno pročitajte značenje, jer gramatički glađa rečenica može sadržajno biti manje precizna.

Primjer revizije na rezultatima radionice

Sljedeća je rečenica namjerno pogrešan početni nacrt:

> Naša analiza dokazuje da očekivanja uzrokuju inflaciju, jer je korelacija 0,70. Potrošači su zato uspješno predvidjeli rast cijena.

U prvom prolazu označite tri problema: korelacija ne identificira uzrok, mjere su nedovoljno opisane i usporedba istog mjeseca nije evaluacija prognoze. U drugom prolazu navedite uzorak i dvije mjere. U trećem ograničite zaključak na opisnu povezanost. Završna verzija može glasiti:

> U hrvatskom mjesečnom uzorku za 2015.–2024. Pearsonova korelacija između godišnje stope promjene HICP-a i salda očekivanih promjena cijena iznosi približno 0,6985. Taj rezultat opisuje pozitivnu linearnu povezanost dviju mjera u istom mjesecu. Saldo nije brojčana prognoza inflacije, a ova usporedba ne identificira uzročni učinak ni prognoznu točnost.

Ovo nije unaprijed zadani zaključak za svaki budući skup. Broj pripada zamrznutoj nastavnoj verziji i može se provjeriti skriptom. Kada se promijene podaci, razdoblje ili postupak, ponovno izračunajte i prepišite odgovarajući dio. AI ne treba „osvježiti" broj prema sjećanju.

Za temu HNB-ove komunikacije primjeren zaključak u ovom trenutku glasi da je riječ o nastavku koji traži dodatne podatke. Ne pišemo da je komunikacija usidrila očekivanja, jer to nismo testirali. Dobro istraživanje može završiti jasno utvrđenom granicom onoga što podaci dopuštaju.

Hrvatski jezik i terminologija

Provjerite stručni naziv u relevantnoj literaturi i dosljedno ga koristite. Opći jezični model može pomoći u formulaciji, ali ne jamči pravilno padežno slaganje ni stručnu prikladnost. Posebno pregledajte duge rečenice u kojima se zajedno pojavljuju nekoliko konstrukata i ograda.

CLASSLA je skup alata za obradu jezika, uključujući jezično označavanje i lematizaciju. To je korisno za istraživanja teksta, ali nije isto što i provjera gramatike cijelog akademskog odlomka. Nemojte rezultat lematizacije predstavljati kao potvrdu da su sve rečenice gramatički i sadržajno ispravne.

U vlastitom malom pojmovniku zadržite razliku između inflacije i razine cijena, salda i postotka, opažanja i ispitanika, korelacije i učinka, standardne pogreške i reziduala. Takva dosljednost često više poboljšava akademski stil od zamjene običnih riječi složenijima.

Završna vježba i procjena vlastitog rada

Napišite približno 200 riječi o jednom rezultatu radionice. Uključite pitanje, podatke i razdoblje, postupak, provjerenu brojku i ograničenje. Zatim zatražite komentar po četiri prolaza, prihvatite samo obrazložene prijedloge i sačuvajte zapis AI pomoći. Provjerite da svaki citat postoji i da svaka brojka odgovara spremljenom izlazu.

Uspjeh ne mjerite brojem promptova, redaka koda ili generiranih stranica. Pitajte se možete li objasniti analizu, koliko ste pogrešaka pronašli, što druga osoba može reproducirati i koliko je vremena trebalo do provjerenog rezultata. To je praktična samoprocjena za radionicu, a ne standardizirana psihometrijska skala.

Na kraju dvaju dana trebate imati povezan trag: pitanje, dokazne zapise, plan, podatke, skriptu, izlaz i vlastitu interpretaciju. Alati se mogu promijeniti. Navika razlikovanja prijedloga od provjerenog zaključka ostaje primjenjiva na sljedeći seminarski rad i na ozbiljniji projekt.