EIZ / PRIRUČNIK ZA SAMOSTALNO ČITANJE

istraživanje uz umjetnu inteligenciju

Prošireni tekst obaju dana radionice

Izvorni materijal / Luka Šikić, UNICATH

Revidirano izdanje / 28. listopada 2026.



OSAM POGLAVLJA / IZVORI · ANALIZA · PISANJE

Materijali za radionicu i samostalno čitanje.

Sadržaj

Kako čitati ovaj priručnik 3

Prvi dan / od pitanja do provjerenih izvora 4

1.1 Postavite istraživačko pitanje 4

1.2 Pronađite i provjerite izvore 6

1.3 Provjerite i uredite sažetak 8

1.4 Pripremite plan analize 10

Drugi dan / od podataka do zaključka 12

2.1 Upoznajte i provjerite podatke 12

2.2 Izradite i objasnite prikaze 14

2.3 Ponovite analizu od početka 16

2.4 Napišite i uredite zaključak 18

Poveznice u sadržaju i bočne oznake PDF-a vode na poglavlja. Podcrtane poveznice uz tvrdnje vode na izvorne dokumente. Tekst možete pretraživati i označavati.

Kako čitati ovaj priručnik

U ovom priručniku prolazimo kroz malo istraživanje, od prvog pitanja do objašnjenja rezultata. Poglavlja prate dva dana radionice, ali možete ih čitati i zasebno. Cijelo vrijeme radimo s istim podacima: 120 mjesečnih opažanja za Hrvatsku od siječnja 2015. do prosinca 2024. Uspoređujemo godišnju stopu HICP-a i saldo očekivanih promjena cijena. Podaci su preuzeti 26. listopada 2026. i spremljeni uz materijale.

Trebat će vam AI alat koji može učitati CSV i provesti izračune. Datoteku dodajte na početku razgovora, a zatim običnim jezikom zadajte što želite saznati. Upite iz priručnika možete preuzeti i prilagoditi svojem pitanju. Programsko predznanje nije potrebno.

Na početku svakog poglavlja nalaze se pitanje za razgovor, primjer i zadatak koji možete sami isprobati. U nastavku objašnjavamo zašto biramo određeni postupak i što iz njegova rezultata možemo saznati. Voditelj može pokazati primjer, a sudionici predložiti drukčiji prikaz ili tumačenje. Ako alat nije dostupan ili izračun ne uspije, razgovor možete nastaviti uz pripremljene grafove i brojke.

Prvi dan biramo pitanje, tražimo i čitamo izvore te pripremamo plan. Drugi dan upoznajemo podatke, izrađujemo prikaze, uspoređujemo razdoblja i pišemo zaključak. Brojevi poglavlja odgovaraju temama na stranicama radionice. Na kraju ćete imati odabrani graf i kratak odgovor na svoje pitanje, spreman za razgovor s kolegom.

Uz pojedine korake povezujemo tekstove i demonstracije Paula Goldsmith-Pinkhama s istraživanjima o radu i učenju uz AI. Zanima nas kako odabrati pitanje, prepoznati pogrešku u mjerenju, protumačiti rezultat i objasniti ga vlastitim riječima. Nalaze tih istraživanja povezujemo s našim primjerom i navodimo što je svako od njih stvarno ispitalo. Pitanja uz odlomke možete otvoriti u skupini ili ih upotrijebiti za samostalni pokušaj.

Autor izvornih materijala je Luka Šikić, UNICATH. Izdanje je revidirano 28. listopada 2026. Podrijetlo podataka i referentni rezultati opisani su u priloženim materijalima radionice.

Prvi dan / od pitanja do provjerenih izvora

1.1 Postavite istraživačko pitanje

Dan 1, tema 1.1 · Vježba 1.1

Primjer iz radionice

Razgovor. Koje pitanje možemo istražiti s dvije mjesečne serije za Hrvatsku?

Primjer. Od teme „inflacija i očekivanja" dolazimo do pitanja o kretanju dviju mjera od 2015. do 2024. i njihovoj povezanosti u različitim razdobljima.

Isprobajte. Odaberite razdoblje ili obrazac koji vas zanima. Zatražite prijedlog pitanja i objasnite kakav bi vam prikaz pomogao odgovoriti na njega.

Što se mijenja kada je lakše provesti ideju

Prije prvog grafa treba pronaći podatke, razumjeti njihove oznake i odlučiti što usporediti. Već tu dobra ideja može zapeti. AI može olakšati taj posao: objasniti nepoznat pojam, predložiti prikaz ili pomoći da isprobamo drukčije objašnjenje. Tako možemo provjeriti vrijedi li razvijati i ideju koju bismo prije odgodili zbog opsežne početne obrade.

Paul Goldsmith-Pinkham u tekstu Research in the Time of AI opisuje kako jeftinija izvedba mijenja istraživački rad. Kada je lakše pripremiti podatke i dobiti rezultate, više pažnje možemo posvetiti izboru pitanja i smislu odgovora. To traži poznavanje teme i dobru prosudbu. Na radionici ćemo zato uz svaki rezultat razgovarati o tome što smo htjeli saznati i što bismo napravili sljedeće.

S našim podacima možemo usporediti ranije i kasnije godine, pogledati razdoblje ubrzanja cijena ili istražiti kreću li se dvije mjere zajedno. Ako želimo objasniti što je uzrokovalo promjenu, morat ćemo osmisliti istraživanje koje može razlikovati moguća objašnjenja.

Koje pitanje vrijedi istražiti

Kad je lako dobiti mnogo prijedloga, treba odlučiti kojemu posvetiti vrijeme. Zamislite da AI predloži usporedbu prosjeka, potragu za neobičnim mjesecima i usporedbu dvaju razdoblja. Svaki je zadatak izvediv, ali svaki otkriva nešto drugo. Koji bi odgovor promijenio vaše razumijevanje teme?

Ning Li u radu The Ideation Bottleneck odvojeno razmatra kvalitetu ideje i izvedbe te u svojoj usporedbi radova istraživača i radova koje je sastavio AI nalazi veću razliku u idejama. Riječ je o radnoj verziji istraživanja u kojoj kvalitetu ocjenjuju AI modeli. Koristimo je kao povod za razgovor o tome što smatramo dobrim pitanjem.

Kad dobijete tri prijedloga iz upita u nastavku, odaberite jedan i objasnite što biste njegovim odgovorom saznali. Recite i zašto biste drugi prijedlog zasad ostavili po strani.

Od teme do pitanja na koje možemo odgovoriti

Tema „inflacija u Hrvatskoj" obuhvaća mnogo različitih istraživanja. Pitanje „Kako su se godišnja stopa HICP-a i saldo očekivanih promjena cijena kretali od 2015. do 2024.?" već određuje zemlju, vrijeme i dvije mjere. Iz njega možemo zamisliti prikaz i objasniti što će čitatelj saznati.

> U učitanom skupu imamo 120 mjeseci za Hrvatsku, godišnju stopu HICP-a i saldo očekivanih promjena cijena. Predloži tri opisna pitanja koja možemo istražiti tim podacima. Za svako objasni što bismo saznali i koji bi prikaz pomogao odgovoriti. Zatim mi postavi jedno pitanje koje će mi pomoći odabrati temu.

Prvi graf može vas navesti na novo pitanje. Recite što vas je na njemu iznenadilo i kako je to promijenilo početnu zamisao. Pitanje koje ste postavili nakon gledanja podataka treba razlikovati od hipoteze koju ste namjeravali ispitati prije analize.

Kako razgovaramo s modelom

Jezični model oblikuje odgovor koristeći naučene obrasce i sadržaj koji mu je dostupan u razgovoru. Tekst obrađuje u manjim jedinicama, tokenima, i postupno sastavlja nastavak. Aplikacija mu može omogućiti i korištenje alata, primjerice pretraživanje, čitanje dokumenta ili izvođenje izračuna. Zbog toga je korisno jasno reći kada tražite ideju, kada objašnjenje pročitanog izvora, a kada račun iz učitane tablice.

Kontekst je sadržaj koji je modelu trenutačno dostupan. U dugom razgovoru raniji dijelovi mogu biti sažeti ili izostavljeni. Prije novog zadatka kratko ponovite pitanje i važnu odluku. Primjerice, podsjetite ga da analizirate cijelo desetljeće i da je saldo izražen u bodovima. Tako smanjujete mogućnost da se nastavak osloni na pogrešnu pretpostavku.

Odaberite dostupan alat koji može čitati datoteke i provoditi izračune. Isprobajte ga na svojem pitanju i pogledajte pomaže li vam razumjeti rezultat. O tome je li pitanje zanimljivo ili koje ste objašnjenje previdjeli razgovarajte i s kolegama.

Brzina i razumijevanje

AI može proizvesti nove rezultate brže nego što ih stignemo razumjeti. Goldsmith-Pinkham taj zaostatak naziva dugom provjere. Na radionici ga možemo prepoznati kada već imamo nekoliko tablica, a još ne znamo objasniti što sažima prva. Tada je korisnije zadržati se na jednom nalazu i razjasniti njegov smisao.

Kad dobijete prvi graf, pokušajte o njemu napisati jednu jasnu rečenicu. Ako to ide sporije od izrade grafa, zastanite i razjasnite što vam je nejasno. Možda je problem u značenju mjere, a možda još ne znate koji je obrazac važan za vaše pitanje.

1.2 Pronađite i provjerite izvore

Dan 1, tema 1.2 · Vježba 1.2

Primjer iz radionice

Razgovor. Kako definicija mjere utječe na usporedbu inflacije i očekivanja?

Primjer. U Eurostatovu opisu HICP-a pronađemo značenje godišnje stope. Vrijednost za ožujak 2022. uspoređuje cijene s ožujkom 2021., iako naša tablica ima zaseban redak za svaki mjesec.

Isprobajte. U metodologiji Europske komisije pronađite pitanje CONS_006 i objašnjenje salda. Objasnite što odgovori govore o budućem kretanju cijena i predložite naziv okomite osi grafa.

Pretraživanje koje prati pitanje

Prije pretrage odredite što vam nedostaje: aktualan podatak, definicija mjere ili istraživanje mogućeg objašnjenja.

AI pretraživanje može predložiti pojmove i sažeti pronađene izvore. Perplexity i slični alati mogu poslužiti za prvi pregled teme. Zatražite poveznice kako biste mogli otvoriti rad koji vas zanima. Ako je alatu dostupan samo sažetak, ne može iz njega pouzdano opisati sve pojedinosti provedenog istraživanja.

Početni upit može biti vrlo kratak.

> Inflacija Hrvatska.

Takav zahtjev ne razlikuje aktualnu stopu od objašnjenja inflacije ili istraživanja očekivanja. Precizniji upit određuje odnos koji vas zanima.

> Pronađi istraživanja o tome kako kućanstva oblikuju očekivanja o budućim promjenama cijena. Usmjeri se na europske zemlje. Za svaki odabrani rad ukratko objasni pitanje, podatke i glavni doprinos temi te navedi poveznicu na izvor. Naznači čitaš li puni tekst ili sažetak.

U međunarodnoj literaturi tražite izraz inflation expectations, a hrvatskim pojmovima dopunite pretragu lokalnih izvora. Zatim je suzite na ono što bi moglo oblikovati očekivanja: iskustvo kupnje, informacije iz medija ili povjerenje u institucije. Pronađeni radovi tada će biti bliži pitanju koje pokušavate postaviti.

Koji izvor služi kojem pitanju

Istraživački rad, praktični vodič i razgovor s istraživačem mogu biti korisni u različitim trenucima. U radu tražimo podatke i postupak koji podupiru nalaz. Vodič može pokazati kako izvesti postupak, a intervju otvoriti pitanje koje vrijedi dalje istražiti. Isti autor u razgovoru može iznijeti pretpostavku koju njegov rad još nije ispitao.

Ako vas razgovor o cijenama navede na pitanje o ulozi medija, pronađite studiju na koju se govornik oslanja. Pogledajte što je doista usporedila. Za izradu prikaza zatim možete upotrijebiti vodič. Objasnite kolegi koji vam je izvor dao ideju, koji podupire tvrdnju, a koji pomaže izvesti analizu.

Pritom razlikujte pronađen zapis od pročitanog rada. Ako alat vidi samo sažetak, potražite autorsku verziju ili pristup preko knjižnice. Izostanak rada iz AI odgovora još ne znači da istraživanje ne postoji.

Što zapravo pitamo potrošače

Za naš je primjer važno razlikovati percepciju prošlih promjena cijena od očekivanja budućih promjena. Anketno pitanje CONS_006 traži procjenu kretanja cijena u sljedećih dvanaest mjeseci u usporedbi s proteklih dvanaest mjeseci. Ponuđene su kategorije odgovora, iz kojih se računa saldo. Njegova vrijednost govori o raspodjeli odgovora prema pravilima ankete. Iz vrijednosti 40 bodova ne možemo zaključiti da ispitanici očekuju stopu inflacije od 40 posto.

Otvorite metodologiju Europske komisije i pročitajte pitanje uz ponuđene odgovore. U Eurostatovu opisu HICP-a pogledajte kako se određuje godišnja promjena. Naša usporedba povezuje mjeru ostvarenog kretanja cijena s kvalitativnom mjerom očekivanja. Različite jedinice kasnije će odrediti kako oblikujemo grafove.

> Objasni razliku između godišnje stope HICP-a i salda iz pitanja CONS_006. Osloni se na ova dva službena opisa. Za svaku mjeru predloži jasnu oznaku osi i jednu rečenicu kojom bih je predstavio osobi koja prvi put vidi graf.

Što bi značio rast salda u našoj tablici? Odgovorite uz formulaciju anketnog pitanja. Govori li o promjeni raspodjele odgovora, o većem očekivanom ubrzanju cijena ili o točno određenoj budućoj stopi? Ako se tumačenja razlikuju, ponovno pročitajte ponuđene kategorije odgovora.

Zašto nam treba baš taj izvor

Članak Meylera i Reiche u ECB Economic Bulletinu pomaže razumjeti kvalitativne i kvantitativne mjere percepcija i očekivanja. Njime objašnjavamo što mjerimo. Korelaciju za hrvatski primjer računamo iz svoje tablice.

Ako dvije studije dolaze do različitih zaključaka, usporedite njihova pitanja i okolnosti. Jedna može ispitivati kratku informacijsku intervenciju, a druga dugoročna kretanja u anketi. Ta razlika može objasniti neslaganje bolje od pokušaja da njihove nalaze spojite u jednu opću tvrdnju.

Odaberite jedan rad zbog kojeg ste promijenili početno mišljenje o temi. Objasnite što biste bez njega pogrešno pretpostavili i što vam nakon čitanja još nedostaje. To će vam pomoći odlučiti što tražiti sljedeće.

1.3 Provjerite i uredite sažetak

Dan 1, tema 1.3 · Vježba 1.3

Primjer iz radionice

Razgovor. Kako sažimanjem možemo promijeniti značenje nalaza?

Primjer. Usporedimo rečenicu o pozitivnoj korelaciji s tvrdnjom da očekivanja uzrokuju inflaciju. Razgovaramo o tome što je u drugoj rečenici dodano izvan samog rezultata.

Isprobajte. Preradite ovaj namjerno pogrešan odlomak. Objasnite komu ili čemu opažanja pripadaju, kako su izražene mjere i na koje se razdoblje zaključak odnosi.

> U uzorku od 120 hrvatskih kućanstava očekivana inflacija 2022. iznosila je prosječno 46,62 %. Korelacija s ostvarenom inflacijom od približno 0,70 pokazuje da su potrošači uspješno predvidjeli buduće cijene. Isti zaključak vrijedi za svako razdoblje od 2015. do 2024.

Što dobar sažetak čuva

Dobar sažetak omogućuje čitatelju da razumije što je istraživanje pitalo, kako je provedeno i što je ustanovilo. Ne mora ponoviti sve pojedinosti. Mora zadržati one bez kojih bi nalaz dobio drukčije značenje, primjerice na koga se odnosi ili što ostaje neobjašnjeno.

Tvrdnja „potrošači su uspješno predvidjeli inflaciju” zahtijeva povezivanje ranijih očekivanja s odgovarajućim kasnijim ishodom. Povezanost dviju mjera iz istog mjeseca sama to ne pokazuje.

Goldsmith-Pinkham u prijedlogu LLM-Friendly Academic Papers zagovara istraživačke materijale iz kojih modeli mogu lakše prenijeti nalaze i njihova ograničenja. To možemo primijeniti i na svoj odlomak. Uz glavni nalaz napišite što iz njega još ne znamo. Čitatelj tako dobiva oba dijela objašnjenja na istome mjestu.

> Sažmi ovaj odlomak za sudionika radionice. Zadrži pitanje, uzorak, značenje mjera i glavni nalaz. Objasni što iz tog nalaza još ne možemo zaključiti. Zatim navedi jednu važnu pojedinost koju si izostavio zbog kratkoće i zašto.

Usporedite odlomak sa sažetkom. Je li kraći tekst jasniji i je li izostavljeno nešto što mijenja smisao? Vratite pojedinost koja čitatelju treba da bi razumio nalaz.

Iste brojke, drukčiji zaključak

Točne brojke mogu pratiti prejak zaključak. Alizadeh i suradnici u radu AI Coding Agents in Social Science pokazuju kako je u jednom istraživačkom zadatku zahtjev za potvrđivanjem hipoteze promijenio zaključke alata Claude Code, uz uglavnom nepromijenjenu raspodjelu procijenjenih koeficijenata. Rezultat upozorava na tumačenje, a njegov opseg ovisi o ispitanom zadatku, modelu i uputama.

Isprobajte jednostavnu nastavnu usporedbu. U dva nova razgovora unesite isti nalaz: korelacija mjesečnih vrijednosti HICP-a i salda za 2015.–2024. iznosi približno 0,6985. U prvom zatražite: „Objasni što ovaj rezultat pokazuje i što iz njega ne možemo zaključiti.” U drugom namjerno usmjerite odgovor: „Objasni zašto ovaj rezultat potvrđuje da očekivanja uzrokuju inflaciju.”

Usporedite odgovore. Je li drugi prihvatio uzročnu tvrdnju ili objasnio zašto nije opravdana? Ako oba odgovora zadrže ograničenja, razgovarajte o tome što su dobro prepoznala. Jedan pokušaj služi raspravi, a za procjenu pouzdanosti trebalo bi više zadataka i ponavljanja.

Kako povezati više pročitanih radova

U pregledu literature treba povezati pročitane radove. Gdje se njihova objašnjenja slažu, a gdje razilaze? Zašto je to važno za naše pitanje? Kod inflacijskih očekivanja radove možemo usporediti prema tome kako mjere očekivanja, koje informacije proučavaju i kakav odnos pokušavaju ustanoviti.

Istraživački načini rada, poput Deep Researcha, mogu pomoći u organiziranju opsežnije pretrage. Prije prikupljanja materijala razgovarajte s alatom o svrsi pregleda. Ako vas zanima medijsko izvještavanje, povijest monetarne politike može biti kratak kontekst, dok više prostora zaslužuju mjerenje medijske pažnje i način na koji studije povezuju informacije s očekivanjima.

> Predloži plan pregleda literature o medijskom izvještavanju i inflacijskim očekivanjima kućanstava. Poveži ga s našim pitanjem o Hrvatskoj. Organiziraj ga oko mjerenja očekivanja, uloge informacija i istraživačkih pristupa. Za svaki dio objasni kako bi pomogao razumjeti temu. Najprije razgovarajmo o planu.

Nakon prvih radova možda ćete promijeniti plan. Ako se dio literature bavi percepcijama, razjasnite razliku između prošlih i budućih promjena cijena. Ako radovi proučavaju druge zemlje, razmislite što bi u Hrvatskoj moglo biti drukčije i zašto bi to utjecalo na zaključak.

Od pregleda literature do vlastite ideje

Neslaganje među radovima može postati početak dobrog pitanja. Primjerice, odnos informacija i očekivanja mogao bi ovisiti o tome je li inflacija dugo niska ili se upravo naglo mijenja. Takva ideja može motivirati opisnu usporedbu razdoblja u našem skupu. Rezultat usporedbe potom pomaže odlučiti kakav bi daljnji projekt bio smislen.

Zatražite nekoliko mogućih objašnjenja istog obrasca. Za jedno od njih pokušajte reći što biste očekivali vidjeti u podacima. Zatim razmotrite bi li isti obrazac mogao nastati i zbog nekog drugog razloga. Takva usporedba pomaže odrediti koje biste podatke trebali prikupiti.

Za istraživanje medija trebali bismo prikupiti podatke o izvještavanju. Naša tablica sadrži samo inflaciju i anketni saldo.

1.4 Pripremite plan analize

Dan 1, tema 1.4 · Vježba 1.4

Primjer iz radionice

Razgovor. Koji prikaz i usporedba odgovaraju našem pitanju?

Primjer. Predložimo slijed: upoznati podatke, prikazati dvije serije, sažeti ih po godinama, usporediti razdoblja i objasniti nalaz.

Isprobajte. Prilagodite plan svojem pitanju. Objasnite zašto biste zadržali jedan predloženi korak, a drugi promijenili ili izostavili.

Plan kao razgovor o izborima

Planom određujemo kako ćemo odgovoriti na pitanje. Ako nas zanima kada su mjere najviše rasle, trebamo vremenski graf. Ako želimo usporediti njihov odnos u dva razdoblja, trebamo iste sažetke za oba. Prije izračuna trebali bismo moći objasniti čemu svaki korak služi.

AI može predložiti nekoliko postupaka. Zatražite da objasni zašto predlaže baš taj graf ili razdoblje i što bismo saznali dodatnim izračunom. Slična biste pitanja postavili i kolegi. Odaberite plan koji odgovara vašem pitanju i koji možete obrazložiti.

> Želim opisati kako se odnos godišnje stope HICP-a i salda očekivanih promjena cijena razlikuje između 2015.–2019. i 2020.–2024. Predloži kratak plan koristeći učitane podatke. Za svaki korak objasni što ćemo saznati. Ponudi jednu jednostavniju varijantu plana i reci što bismo njome izgubili.

Prođite kroz predložene rezultate. Donosi li svaki graf nešto novo? Ako nekoliko njih pokazuje gotovo isto, odaberite najjasniji. Ostavite dovoljno vremena da protumačite ono što ste dobili.

Dijelovi istraživanja ovise jedni o drugima

Goldsmith-Pinkham u tekstu AI and the Research O-Ring uspoređuje istraživanje s procesom čiji koraci ovise jedni o drugima. Slabost jednog koraka može umanjiti vrijednost cijelog rada. Ta ekonomska analogija dobro opisuje i problem koji se može pojaviti u našem primjeru.

U našem primjeru pogrešno razumijevanje salda utjecalo bi na oznaku osi, usporedbu s HICP-om i tekst zaključka. Račun može biti točan, a tumačenje i dalje pogrešno. Zato planiranje uključuje razgovor o mjerama i pitanju, a kasniji rezultati mogu nas vratiti na te odluke.

Ponekad nas rezultat vrati na početno pitanje. Ako graf pokaže da se odnos mijenja kroz vrijeme, možda će nas više zanimati razlike među razdobljima nego prosjek za cijelo desetljeće. Objasnite što vas je navelo na tu promjenu i prilagodite joj plan.

Zadajte izvediv korak

Za početak zatražite jedan prikaz ili jednu usporedbu. Kad razumijete rezultat, odlučite što dalje. Ako alat predloži novu metodu, pitajte koje pitanje ona rješava i kakve podatke zahtijeva. Njezin naziv sam po sebi nije razlog da je uključite u analizu.

> Za početak prikaži obje mjere kroz svih 120 mjeseci u odvojenim panelima sa zajedničkom vremenskom osi. Objasni što se iz takva prikaza može vidjeti. Zatim predloži jednu usporedbu koja bi pomogla odgovoriti na moje pitanje o razdobljima.

Ako je prijedlog preširok, suzite ga običnim jezikom: „Zadržimo se na usporedbi razdoblja” ili „Objasni najprije kako bi se čitao taj prikaz”. Ako odgovor pretpostavlja medijske podatke koje nemamo, razdvojite zadatak koji je sada izvediv od zamisli za novi projekt.

Uputu koja vam se pokazala korisnom možete sačuvati i prilagoditi sljedećem zadatku. Goldsmith-Pinkham o tome piše kroz ponovno upotrebljive upute, odnosno skills. Na radionici to može biti jednostavan upit za izradu prikaza ili komentar na tekst. Pri ponovnoj uporabi provjerite odgovara li uputa novim podacima i pitanju.

Što delegiramo, a o čemu odlučujemo

Anton Korinek u vodiču AI Agents for Economic Research opisuje sustave koji mogu planirati, koristiti alate i povezati više istraživačkih koraka. To otvara mogućnost da im prepustimo dulji zadatak. Prije toga treba razjasniti odluke koje će tijekom rada morati donositi.

Za godišnju tablicu možemo zatražiti izračun prosjeka i izradu prikaza. Mi trebamo objasniti zašto uspoređujemo određene godine i što taj prosjek znači. Ako se pojavi praznina u podacima, odluka o njezinu popunjavanju može promijeniti rezultat. U tom slučaju zatražite objašnjenje mogućnosti prije nastavka.

Prođite svoj plan s kolegom. Koji korak možete odmah povjeriti alatu, a prije kojega treba donijeti odluku? Opišite je običnim jezikom. Takav dogovor ostaje koristan i kada prijeđete u drugu aplikaciju.

Povežite prvi i drugi dan

Na kraju prvog dana svatko ukratko predstavi pitanje, odabrani prikaz i usporedbu koju želi napraviti. Kolega može pitati zašto je baš ta usporedba korisna ili predložiti jednostavniji put. Taj razgovor često razjasni dio plana koji je u razgovoru s AI-jem ostao neodređen.

Na kraju razgovora zatražite kratak sažetak pitanja i dogovorene usporedbe. Od njega možete krenuti drugi dan. Ako se sesija prekine, ponovno dodajte isti CSV i navedite što želite istražiti. Tako rad možete nastaviti i u drugom alatu.

Drugi dan / od podataka do zaključka

2.1 Upoznajte i provjerite podatke

Dan 2, tema 2.1 · Vježba 2.1

Primjer iz radionice

Razgovor. Što predstavlja jedan redak naše tablice i kako iz njega čitamo dvije mjere?

Primjer. Zatražimo kratak opis učitanog skupa i pogledamo nekoliko mjeseci na početku i kraju razdoblja. Povežemo prikazane vrijednosti sa značenjem HICP-a i anketnog salda.

Isprobajte. Odaberite jedan mjesec i objasnite što njegove vrijednosti govore, na koje se vrijeme odnose i što biste o njima htjeli saznati.

Prvi pogled na tablicu

Nastavite u razgovoru iz prvog dana. Ako počinjete ovdje, preuzmite CSV radionice, dodajte ga u alat koji može izvršavati analizu i navedite pitanje koje ste odabrali. Za prvi pregled dovoljan je kratak zahtjev.

> Upoznaj me s učitanom tablicom. Opiši što predstavlja jedan redak, koliko mjeseci obuhvaća i koje dvije mjere analiziramo. Prikaži nekoliko redaka s početka i kraja razdoblja. Reci jesu li mjeseci uzastopni i postoje li praznine u brojčanim serijama. Objašnjenje i rezultate prikaži u razgovoru, bez programskog koda.

Očekujemo 120 različitih uzastopnih mjeseci od siječnja 2015. do prosinca 2024. Obje brojčane serije imaju vrijednost za svaki mjesec. Prazne oznake statusa u našoj tablici znače da dodatni status podatka nije naveden. U rječniku podataka opisani su stupci i jedinice.

Jedan redak odnosi se na jedan mjesec u Hrvatskoj. Anketni odgovori potrošača već su sažeti u pokazatelj. Zato iz ove tablice ne možemo opisivati razlike među kućanstvima. Za takvo pitanje trebali bismo podatke o pojedinim ispitanicima.

Dvije mjere, dva vremenska značenja

HICP je u tablici izražen godišnjom stopom promjene. Podatak za ožujak uspoređuje cijene s ožujkom prethodne godine. Saldo očekivanja nastaje iz odgovora o budućem kretanju cijena. Obje vrijednosti bilježimo u istom retku, ali one govore o različitim vremenskim usporedbama.

Usporedbom vrijednosti iz istog mjeseca opisujemo kako se mjere kreću zajedno. Ako nas zanima jesu li potrošači dobro predvidjeli buduću inflaciju, moramo odrediti koji kasniji ishod odgovara njihovu očekivanju. Treba razmotriti i što su mogli znati kada su odgovarali. Na radionici počinjemo jednostavnijom usporedbom vrijednosti iz istog mjeseca.

> Odaberi ožujak 2022. i objasni obje vrijednosti običnim jezikom. Uz svaku navedi jedinicu i vremensku usporedbu na koju se odnosi. Predloži zatim jedno pitanje na koje nam taj redak sam ne može odgovoriti, ali bi nam pomogao pogled na okolne mjesece.

Vrijedi se zadržati na tom jednom retku. Kad možete objasniti obje vrijednosti, bit će lakše čitati cijeli niz i procijeniti odgovara li AI-jev opis onome što podaci mjere.

Što podaci trebaju da bi postali korisni

Goldsmith-Pinkham u demonstraciji Large Datasets and Structured Databases pokazuje kako organizirani podaci i njihovi opisi olakšavaju istraživanje. Jedan od problema u njegovu primjeru nastaje zbog promjene identifikatora, što nalikuje stvarnoj promjeni u podacima dok se ne razumije njihova struktura. Poruka se odnosi i na male tablice: značenje podataka određuje koje su usporedbe opravdane.

Za naš skup već znamo obuhvat i značenje mjera. U drugom projektu trebat će provjeriti jesu li se kroz vrijeme mijenjali uzorak, anketno pitanje ili način mjerenja. Takva promjena može utjecati na usporedbu čak i kada tablica izgleda uredno. AI može pomoći pronaći i objasniti odgovarajuću dokumentaciju.

Zato zadatak „očisti podatke” često traži razgovor prije izvršavanja. Visoka vrijednost može biti upravo događaj koji želimo proučiti. Nedostajuća vrijednost i nula imaju različito značenje. U ovoj radionici zadržavamo izvorne brojčane vrijednosti i cijelo razdoblje, a uži odabir koristimo samo za jasno određenu usporedbu ili prikaz.

Kada AI stvara novu mjeru

Ako AI označi ton medijskih članaka, njegove oznake postaju podatak za daljnju analizu. Zamislite da svaku pojavu riječi „poskupljenje” protumači kao zabrinutost, pa tako označi i neutralne vijesti. Tada bismo mogli precijeniti zabrinut ton upravo u mjesecima kada se o cijenama više izvještava. Pogreška u oznaci može promijeniti i odnos koji kasnije procjenjujemo.

Ludwig, Mullainathan i Rambachan u radu Large Language Models: An Applied Econometric Framework objašnjavaju kako validacijski uzorak omogućuje procjenu pogrešaka AI mjerenja i njihovo uzimanje u obzir u daljnjoj analizi.

Za vježbu usporedite nekoliko vlastitih oznaka s AI oznakama. Razgovarajte o neslaganju: je li kategorija nejasna ili je model pogrešno protumačio tekst? Za istraživanje treba odabrati zaseban validacijski uzorak i procijeniti kako pogreške utječu na nalaz. To bi bio novi projekt. U našem CSV-u medijskih oznaka nema.

Koliko posla prepustiti asistentu

Asistentu možete prepustiti pregled tablice ili izradu grafova. Prije nego što pokrenete zadatak, pokušajte predvidjeti dio rezultata koji možete zaključiti iz opisa podataka.

Koliko redaka treba imati godišnja tablica za deset godina? Koliko mjeseci ulazi u svaki prosjek? Kad dobijete rezultat, usporedite ga s onim što ste očekivali. Ako se razlikuje, zatražite objašnjenje prije nego što nastavite.

2.2 Izradite i objasnite prikaze

Dan 2, tema 2.2 · Vježba 2.2

Primjer iz radionice

Razgovor. Kako prikazati dvije mjere da se njihovo kretanje može usporediti?

Primjer. Zatražimo dva vremenska grafa sa zajedničkom osi mjeseci i godišnju tablicu prosjeka. Objasnimo što saznajemo iz grafa, a što iz tablice.

Isprobajte. Prilagodite prikaz svojem pitanju, primjerice izdvojite 2020.–2024. Objasnite koji se obrazac sada lakše vidi i zašto.

Naručite prikaz koji odgovara pitanju

Prije izrade grafa recite što želite vidjeti. Za pitanje o promjenama kroz vrijeme treba sačuvati redoslijed mjeseci. Za usporedbu godina može pomoći godišnji sažetak. Prikaz biramo prema pitanju koje nas zanima.

Naše dvije serije imaju različite jedinice. Prikazat ćemo ih u dva panela, jedan iznad drugoga, sa zajedničkom vremenskom osi. Tako možemo usporediti trenutke promjene uz zasebnu skalu svake mjere.

> Iz učitanog CSV-a izradi dva vremenska grafa za 2015.–2024., jedan iznad drugoga, sa zajedničkom osi mjeseci. Na prvom prikaži godišnju stopu HICP-a u postocima, a na drugom saldo očekivanih promjena cijena u bodovima. Dodaj jasne naslove i izvore Eurostat i DG ECFIN, s datumom preuzimanja 26. listopada 2026. Prikaži grafove i kratko objasni njihov sadržaj, bez programskog koda.

Pogledajte graf prije nego što pročitate AI-jevo objašnjenje. Što vam prvo privlači pažnju: nagli vrhunac, dulje razdoblje rasta ili dio u kojem se serije razilaze? Zatim pročitajte ponuđeni opis. Ako je alat istaknuo nešto drugo, razmislite koji je obrazac važniji za vaše pitanje.

Što dobivamo godišnjom tablicom

Godišnja tablica olakšava usporedbu 2021. i 2022. Za pitanje kada je promjena počela i koliko je trajala treba se vratiti mjesečnom grafu. Zato ćemo pripremiti oba prikaza.

> Napravi tablicu godišnjih prosjeka za obje mjere. Uz svaku godinu navedi broj mjeseci koji ulaze u prosjek. Prosjek HICP-a nazovi prosjekom mjesečnih godišnjih stopa, a saldo izrazi u bodovima. Prikaži dvije decimale. Zatim usporedi 2021. i 2022. i objasni što je godišnje sažimanje sakrilo u odnosu na mjesečni graf.

Za 2021. prosjek mjesečnih godišnjih stopa HICP-a iznosi približno 2,68 %, a prosjek salda 28,26 bodova. Za 2022. odgovarajuće su vrijednosti 10,63 % i 46,62 boda. Svaki prosjek obuhvaća dvanaest mjeseci. Godišnji prosjek stopa u ovoj tablici treba razlikovati od

godišnje promjene prosjeka samog indeksa cijena. Tu drugu veličinu računali bismo iz razina indeksa.

Zamislite da imate samo godišnju tablicu. Koji biste dio priče mogli ispričati, a za što bi vam nedostajali mjeseci? Vratite se grafu i pronađite promjenu koju godišnji prosjek skriva.

Promijenite jednu stvar i objasnite učinak

Za vlastiti pokušaj odaberite jednu promjenu prikaza. Možete izdvojiti kasnije razdoblje, jasnije označiti godine ili prilagoditi naslov pitanju koje postavljate. Prije izmjene recite što očekujete da će biti lakše vidjeti. Nakon nje usporedite prikaze.

> Izradi dodatnu verziju grafova samo za 2020.–2024. Zadrži iste definicije mjera. Cijeli izvorni skup ostaje dostupan za kasniju usporedbu. Objasni što uži vremenski prikaz ističe i koji se kontekst gubi izostavljanjem ranijih godina.

Izdvojeni prikaz obuhvaća 60 mjeseci. Može olakšati čitanje promjene, ali izbor početka i kraja utječe na dojam. Ako uspoređujete nekoliko grafova iste mjere, razgovarajte i o rasponu okomite osi. Jednaka skala olakšava procjenu veličine razlika između prikaza.

Odluke skrivene u gotovom grafu

Kad zatražite „najbolji graf”, alat mora odabrati što će prikazati, kako će sažeti podatke i koju će usporedbu istaknuti. Pogledajte koji je izbor napravio. U našem primjeru godišnji prosjek sažima dvanaest mjeseci, dok mjesečni prikaz čuva trenutak promjene. Naslov zatim usmjerava pažnju čitatelja na jedan obrazac.

Za udjele treba razjasniti i nazivnik. Zamislite da prikupljate medijske tekstove o inflaciji. Njihov broj može rasti, a udio padati ako ukupan broj tekstova raste još brže. Uključivanje novog portala također može promijeniti sliku. Što graf tada opisuje: izvještavanje u istim izvorima ili promjenu obuhvata zbirke?

Vratite se svojem prikazu. Objasnite jednu odluku koju je alat donio bez vašeg izričitog zahtjeva i predložite drugu mogućnost. Koja bolje odgovara vašem pitanju? Odabir obrazložite onime što čitatelj treba moći usporediti.

Što graf govori čitatelju

Goldsmith-Pinkham u demonstraciji From an Empty Folder to a Figure pokazuje kako uz AI od početne ideje dolazi do grafa. U našem su primjeru podaci već pripremljeni. Sada možemo pogledati je li prikaz koji smo zatražili doista koristan za pitanje kojim se bavimo.

Pokažite graf kolegi i pitajte što prvo primjećuje. Ako vidi nešto drukčije od onoga što ste željeli istaknuti, razmotrite naslov, oznake osi i popratno objašnjenje. Možda treba promijeniti i sam prikaz.

2.3 Ponovite analizu od početka

Dan 2, tema 2.3 · Vježba 2.3

Primjer iz radionice

Razgovor. Koliko naš opis odnosa ovisi o razdoblju koje promatramo?

Primjer. Iz cijelog CSV-a ponovno izdvojimo dvanaest vrijednosti HICP-a za 2022. Njihov zbroj iznosi 127,6, a prosjek približno 10,6333 %. Povežemo taj račun s godišnjom tablicom.

Isprobajte. Usporedite korelaciju za cijelo desetljeće i za dva petogodišnja razdoblja. Objasnite što se izgubi kada odnos opišemo samo jednim brojem.

Vratite se cijelom skupu

U prethodnom poglavlju možda ste prikazali samo 2020.–2024. Sada nam opet treba svih 120 mjeseci kako bismo usporedili ranije i kasnije razdoblje. To jasno navedite u novom upitu, da alat ne nastavi računati na prethodno izdvojenim podacima.

> Ponovno kreni od cijelog učitanog CSV-a. Prikaži svih dvanaest godišnjih stopa HICP-a za 2022., njihov zbroj i prosjek. Zatim izračunaj Pearsonovu korelaciju između dviju mjera iz istog mjeseca za 2015.–2024., 2015.–2019. i 2020.–2024. Uz svaki rezultat navedi broj mjeseci. Prikaži tablicu i objašnjenje postupka običnim jezikom, bez programskog koda.

Za 2022. zbroj dvanaest vrijednosti dijelimo s dvanaest i dobivamo približno 10,63 %. Tako možemo pratiti kako je nastao jedan rezultat godišnje tablice. Kod složenijeg izračuna zatražite objašnjenje onoga što se uspoređuje i načina na koji su opažanja odabrana.

Što korelacija sažima

Pearsonova korelacija opisuje linearnu povezanost parova vrijednosti. U našoj spremljenoj verziji podataka iznosi približno 0,6985 za 2015.–2024., uz 120 mjeseci. Za 2015.–2019. iznosi 0,8279, a za 2020.–2024. 0,5342, uz po 60 mjeseci. To su opisni rezultati iz referentne analize.

Prema ovom pokazatelju povezanost je jača u ranijem podrazdoblju. Jedna korelacija za cijelo desetljeće skriva tu razliku. Vratite se grafovima i pogledajte kada su se serije kretale slično, a kada su se razilazile.

Iz same razlike među korelacijama ne možemo zaključiti da se dogodio strukturni lom ili da je jedna mjera promijenila drugu. Na rezultat mogu utjecati zajednički šokovi, vremenska ovisnost i odabrano razdoblje. Za provjeru tih objašnjenja treba zasebna analiza. Zasad možemo obrazložiti zašto bi tu razliku vrijedilo dalje istražiti.

Kada više izračuna postane novo istraživanje

AI nam olakšava naručivanje dodatnih usporedbi. Možemo zatražiti drukčiji početni mjesec, kraći raspon ili pomicanje jedne serije u odnosu na drugu. Svaka od tih odluka mijenja pitanje koje broj sažima. Prije izračuna objasnite zašto vas određena promjena zanima.

Ako isprobavate različita razdoblja kako biste upoznali podatke, predstavite taj rad kao istraživanje obrazaca. Odabir samo najjače korelacije nakon mnogo pokušaja ne pokazuje da je upravo taj odnos najvažniji. Za prognozu biste trebali odrediti cilj i vremenski horizont te odvojiti razdoblje na kojem procjenjujete uspješnost.

Goldsmith-Pinkham u raspravi o AI one-shot papers upozorava da automatizirana izvedba može posezati za poznatim metodama koje i dalje zahtijevaju istraživačku prosudbu. Naš je primjer jednostavniji, ali otvara isto pitanje: što bi nam dodatna metoda omogućila zaključiti i zašto su njezine pretpostavke ovdje uvjerljive?

> Predloži jedno moguće objašnjenje razlike među podrazdobljima i jedno alternativno objašnjenje. Za svako reci koje dodatne podatke ili usporedbe trebamo da bismo ih mogli razlikovati. Poveži prijedloge s onim što smo stvarno vidjeli na grafovima.

Ponovljen rezultat i opravdan zaključak

Dobiti isti broj važan je korak provjere. Xu i Yang u radu Scaling Reproducibility opisuju postupak koji ponovno izvršava analize i uspoređuje dobivene procjene s objavljenima. Ponavljanje pokazuje možemo li iz sačuvanih materijala dobiti rezultat. Za tumačenje još treba procijeniti odgovaraju li mjere i postupak istraživačkom pitanju.

Drukčiju provjeru ispituje Toda u radu Can AI Refute Economic Theory?. U četiri teorijska rada s poznatim pogreškama nijedan ispitani model nije pronašao stvarnu pogrešku bez znatnog ljudskog usmjeravanja. To je ograničen pokus koji otvara pitanje što provjeravatelj mora znati da bi pomoć alata bila korisna.

Vratite se korelaciji iz naše tablice. Ako ponovimo račun i dobijemo 0,6985, što smo time provjerili? Što bi još trebalo ustanoviti prije tvrdnje da očekivanja uzrokuju inflaciju? Pokušajte zasebno objasniti što opravdava broj, a što bi opravdalo takav zaključak.

Možemo li objasniti dobiveni rezultat?

U svojem primjeru suradnje na empirijskoj analizi Goldsmith-Pinkham opisuje slučaj u kojem je zapis rada tvrdio da je analiza provedena, iako nije bila. Zato uz objašnjenje postupka treba pogledati i stvarni rezultat. U našoj vježbi to znači otvoriti tablicu ili graf i povezati ih s pitanjem, mjerama i razdobljem koje smo zadali.

Ako rezultat još ne možete objasniti, razjasnite što vam nedostaje prije nove tablice. Time smanjujete dug provjere s početka priručnika.

Uz podatke i rezultate zatražite datoteku s postupkom koji računalo može ponovno izvršiti. Isti razgovorni upit može dati drukčiji postupak. Kolegi objasnite što ste sačuvali i kako može ponoviti vaš rad.

2.4 Napišite i uredite zaključak

Dan 2, tema 2.4 · Vježba 2.4

Primjer iz radionice

Razgovor. Što biste o svojem nalazu objasnili osobi koja nije sudjelovala u analizi?

Primjer. Napišemo vlastito tumačenje jednoga grafa, zatražimo komentare na argument i odlučimo kako ćemo ga preraditi.

Isprobajte. Sastavite oko 150 riječi odgovora na svoje pitanje. Uz graf pokažite broj koji podupire glavni nalaz i objasnite jedno otvoreno pitanje. Kolegi obrazložite jednu odluku pri uređivanju.

Pisanje razvija razumijevanje

Pokušajte napisati što vaš graf pokazuje. Možda ćete zapeti na jednostavnom pitanju: zašto ste odabrali baš to razdoblje ili što ta brojka govori o inflaciji? Takav zastoj otkriva što još treba razjasniti. Zato prvo napišite vlastito tumačenje, makar bilo nespretno.

Goldsmith-Pinkham u tekstu Writing & Thinking with AI Assistance razlikuje pomoć u rutinskom pisanju od prepuštanja oblikovanja argumenta. Predlaže i način rada u kojem asistent komentira nacrt, a autor ga zatim sam prerađuje. To ćemo isprobati u završnoj vježbi. Jezičnu pomoć možete zatražiti kada ste zadovoljni objašnjenjem nalaza.

Za naš zaključak počnite odgovorom na odabrano pitanje. Ako vas zanimaju razlike među razdobljima, istaknite tu usporedbu. Ako ste proučavali promjene tijekom 2021. i 2022., usmjerite tekst na te godine. Ne trebate prepričati svaku tablicu koju ste proizveli.

> Pročitaj moj nacrt zaključka i daj komentare bez prepisivanja. Izdvoji mjesto na kojem argument nije jasan, pitanje na koje još nisam odgovorio i tvrdnju kojoj treba bolje obrazloženje. Za svaki komentar objasni zašto je važan za moje istraživačko pitanje. Zatim pričekaj moju preradu.

Odaberite komentar koji vam pomaže popraviti tekst. Ako ne razumijete što bi se predloženom promjenom dobilo, zatražite objašnjenje. Komentar koji ne odgovara vašem pitanju ili analizi možete odbaciti. U oba slučaja pokušajte objasniti svoju odluku.

Povežite pitanje, graf i nalaz

Počnite od onoga što ste uspoređivali. Zatim pokažite važan obrazac na grafu ili broj iz tablice i objasnite što govori o pitanju. Recite i što je ostalo otvoreno. Čitatelj bi trebao moći pratiti zaključak bez pristupa cijelom razgovoru s alatom.

Za usporedbu godišnjih sažetaka možemo napisati sljedeći odlomak.

> U hrvatskim podacima prosjek mjesečnih godišnjih stopa HICP-a porastao je s 2,68 % u 2021. na 10,63 % u 2022. U istim je godinama prosjek salda očekivanih promjena cijena porastao s 28,26 na 46,62 boda. Godišnji sažeci tako pokazuju rast obiju mjera, dok mjesečni grafovi omogućuju detaljniji opis njihova kretanja. Iz te usporedbe još ne možemo odrediti uzrok promjene ni uspješnost predviđanja buduće inflacije.

Odlomak opisuje promjenu između dviju godina. Ako vas zanima povezanost među razdobljima, oslonite se na korelacije iz prethodnog poglavlja i objasnite što one uspoređuju. U zaključak uključite rezultate koji odgovaraju na vaše pitanje.

Jezična pomoć i vlastiti glas

Kad znate što želite reći, zatražite pomoć s jezikom. Asistent može skratiti predugu rečenicu, predložiti bolji redoslijed ili pomoći pri pisanju na jeziku koji vam nije prvi. Pročitajte prijedlog i procijenite izražava li jasno ono što ste mislili.

> Predloži jezičnu doradu ovog odlomka. Zadrži moje tumačenje, brojke i nazive mjera. Objasni jednu važnu promjenu koju predlažeš. Ako ti sadržaj nije jasan, najprije me pitaj što želim reći na tom mjestu.

Pazite na razliku između inflacije i razine cijena, salda i postotka te očekivanja i percepcija. Birajte izraze koje biste upotrijebili i kada kolegi usmeno objašnjavate nalaz. Ako rečenicu morate nekoliko puta pročitati da biste je razumjeli, pokušajte je pojednostavniti.

Pokažite kolegi završni graf i objasnite glavni nalaz bez čitanja odlomka. Njegova pitanja mogu otkriti gdje tekst treba dopuniti. Ako ste nakon AI komentara promijenili argument, recite što ste promijenili i zašto.

Što ostaje kad zatvorite razgovor

Dovršen tekst pokazuje što smo proizveli. Razumijevanje možemo isprobati novim pitanjem. Liu i suradnici u radu AI Assistance Reduces Persistence and Hurts Independent Performance nalaze slabiji samostalan učinak nakon uklanjanja AI pomoći nego u kontrolnoj skupini. Ispitivali su kratke zadatke s razlomcima i razumijevanjem pročitanog. Ti rezultati ne daju izravnu procjenu dugoročnog učenja ekonomije.

Zatvorite razgovor i uz svoj graf objasnite zašto ste odabrali baš tu usporedbu. Neka kolega postavi novo pitanje, primjerice što bi se izgubilo prikazom samo godišnjih prosjeka. Pokušajte odgovoriti vlastitim riječima, pa se vratite dijelu koji vam je ostao nejasan. Za njega zatražite objašnjenje ili mali trag i ponovno pokušajte. Što biste sada znali napraviti u sličnom zadatku s drugim podacima?

Od zaključka do sljedećeg pitanja

Naša analiza može potaknuti pitanje o ulozi medija ili komunikacije HNB-a. Za takav projekt trebali bismo povezati podatke o cijenama i očekivanjima s novom zbirkom tekstova. Goldsmith-Pinkhamova demonstracija pretvaranja objava u strukturirane podatke pokazuje kako AI može olakšati takav početak istraživanja.

Za temu medija najprije odaberite mali skup članaka i pitanje koje njima želite istražiti. Dogovorite što znači medijska pažnja ili ton, razmotrite nekoliko primjera zajedno i usporedite vlastita tumačenja s klasifikacijom alata. Tek kada razumijete tu mjeru, ima smisla širiti zbirku i povezivati je s drugim podacima. Odnos koji tada pronađete i dalje traži zasebno objašnjenje prije uzročnog zaključka.

Na kraju usporedite iskustva. Što vam je alat olakšao? Oko koje ste odluke morali najviše razmišljati? Odaberite jedno pitanje kojem biste se htjeli vratiti nakon radionice.